

Miskolci Egyetem
Gépészmérnöki és Informatikai Kar
Általános Informatikai Intézeti Tanszék



Videójátékok adatainak elemzése Python alapú gépi tanulási eszközök segítségével

Diplomamunka

Készítette:

Név: Drig Dávid

Neptunkód: EZ3YRC

Szak: Mérnökinformatikus MSc
Alkalmazásfejlesztő szakirány

EREDETISÉGI NYILATKOZAT

Alulírott **Drig Dávid**; Neptun-kód: EZ3YRC a Miskolci Egyetem Gépészmérnöki és Informatikai Karának végzős Mérnök-informatikus szakos hallgatója ezennel büntetőjogi és fegyelmi felelősségem tudatában nyilatkozom és aláírással igazolom, hogy *Videójátékok adatainak elemzése Python alapú gépi tanulási eszközök segítségével* című diplomamunkám saját, önálló munkám; az abban hivatkozott szakirodalom felhasználása a forráskezelés szabályai szerint történt.

Tudomásul veszem, hogy diplomamunka esetén plágiumnak számít:

- szó szerinti idézet közlése idézőjel és hivatkozás megjelölése nélkül;
- tartalmi idézet hivatkozás megjelölése nélkül;
- más publikált gondolatainak saját gondolatként való feltüntetése.

Alulírott kijelentem, hogy a plágium fogalmát megismertem, és tudomásul veszem, hogy plágium esetén diplomamunkám visszautasításra kerül.

Miskolc, év hó nap

.....

Hallgató

Tartalomjegyzék

1. Bevezetés	1
2. Adatok előkészítése	2
2.1. Steam szolgáltatás és a kezelt adatai	2
2.1.1. A Steam szolgáltatás áttekintése	2
2.1.2. A Kaggle platform szerepe	3
2.1.3. Az elemzés során használt eszközök	3
2.1.4. Letöltés, formátum és mennyiségi jellemzők	3
2.2. A vizsgálandó adathalmaz áttekintése	5
3. Adatok egységes struktúrába szervezése	10
3.1. Relációs sémák elemzése	11
3.2. Normalizálás	12
3.2.1. Az A adathalmaz normalizálása	12
3.2.2. A B adathalmaz normalizálása	14
3.2.3. A C adathalmaz normalizálása	16
3.2.4. A D adathalmaz normalizálása	18
3.3. Adathalmazok összefésülése	21
3.3.1. Az összefésülés logikai folyamata	21
3.3.2. Az összefésülés megvalósítása	22
3.4. Az egységesített adathalmaz felbontása	26
3.4.1. A split folyamat lépései	26
3.4.2. A létrehozott táblák	26
3.4.3. A split folyamat működési elvei	27
4. Leíró statisztikák	28
4.1. Előzetes vizsgálatok	28
4.1.1. Források közötti átfedések – Venn-diagram	29
4.1.2. Forrásösszegzés (Source Summary)	30
4.1.3. Integritásvizsgálat	31

4.2.	Grafikonok	32
4.2.1.	Hisztogramok és trendvizualizációk	33
4.2.2.	Forrás szerinti bontás (A, B, C kategória)	34
4.2.3.	Top 5 műfaj időbeli trendje	37
4.2.4.	Éves növekedési faktor (logaritmikus skálán)	39
4.2.5.	Év $\times$ nap hőtérkép	39
4.2.6.	Év $\times$ (ISO hét $\times$ hét napja) hőtérkép	40
4.3.	Szezonális mintázatok – havi, heti és napi bontás	41
4.3.1.	Havi szezonális mintázatok	42
4.3.2.	Heti szezonális mintázatok	42
4.3.3.	Napi mintázatok ISO-heti igazítással	43
4.4.	2026-os előrejelzés logaritmikus skálán illesztett lineáris trend alapján	43
4.4.1.	Az előrejelzés pontosságának vizsgálata	44
4.5.	Modellvalidáció – 2024 visszateszt	47
5.	Osztályozási problémák	48
5.1.	Kutatási módszertan és feldolgozási lépések	48
5.2.	Vizsgálat 1: Videójáték sikerességének becslése	50
5.2.1.	A probléma specifikációja (cél)	50
5.2.2.	Adatkijelölés és jellemzők	50
5.2.3.	Előfeldolgozás	51
5.2.4.	Tanítás/tesztelés és metrikák	52
5.2.5.	Mennyiségi jellemzők és javasolt ábrák	52
5.3.	Vizsgálat 2: Multiplayer vs. singleplayer osztályozás	54
5.3.1.	A probléma specifikációja (cél)	54
5.3.2.	Adatkijelölés és jellemzők	54
5.3.3.	Előfeldolgozás	56
5.3.4.	Tanítás/tesztelés és metrikák	56
5.3.5.	Mennyiségi jellemzők és osztályeloszlás	57
5.4.	Összegzés és további vizsgálati lehetőségek	59
6.	Osztályozási feladatok megoldása	60
6.1.	Domain 1: Videójáték sikerességének elemzése	60
6.1.1.	A sikeresség-becslés eredményeinek értelmezése	60
6.1.2.	A sikerességet befolyásoló jellemzők értelmezése	61
6.1.3.	A jellemzők számának hatása a prediktív teljesítményre	62
6.2.	Domain 2: Multiplayer vs. singleplayer osztályozás	63
6.2.1.	A multiplayer besorolást befolyásoló jellemzők értelmezése	64

7. Módszerek és eredményeik összehasonlítása	66
7.1. Domain 1: Videójáték sikerességének elemzése	66
7.1.1. A Random Forest és Gradient Boosting modellek összehasonlítása	66
7.1.2. Az alkalmazott osztályozási modellek és értékelésük	67
7.2. Domain 2: Multiplayer vs. singleplayer osztályozás	68
7.2.1. Az alkalmazott modellek áttekintése	68
7.2.2. Teljesítménybeli különbségek elemzése	68
7.2.3. A strukturált jellemzők hatása	69
7.2.4. Összegző értékelés	69
8. Összegzés	70
9. Summary	72
Irodalomjegyzék	74
A. Relációs adatmodell ábrák	78
B. Osztálydiagramok	84

1. fejezet

Bevezetés

A videójátékok területén keletkező adatok elemzése napjainkban egyre fontosabb szerepet tölt be mind a kutatás, mind az ipari alkalmazások szempontjából. A Steam [1] platformon elérhető videójátékok jellemzőire, játékmenetére és teljesítményére vonatkozó adatok megfelelő feldolgozása lehetőséget teremt különböző mintázatok felismerésére, valamint prediktív és osztályozási problémák megoldására. A nagy mennyiségű és heterogén adatok kezelése azonban megfelelő adat-előkészítési és elemzési módszereket igényel.

A diplomamunka során három, a Kaggle [2] platformon elérhető, Steamhez kapcsolódó videójáték-adathalmaz kerül feldolgozásra. Az adatkészletek kezdetben különálló munkafüzetekben kerülnek elemzésre, az egyes adathalmazok szerkezetének és minőségének megismerése érdekében. Az előzetes vizsgálatot követően az adatok tisztítása és normalizálása történik meg annak érdekében, hogy az eltérő forrásból származó adatok egységes formában legyenek kezelhetők.

A normalizált adathalmazok ezt követően összevonásra kerülnek egy egységes, nagyobb adatkészletté. Az adatbázis logikus felépítése és a hatékony elemzés érdekében az összevont adathalmaz további, tematikusan elkülönülő táblákra kerül bontásra, biztosítva az adatok átlátható kezelését.

Az előkészített adatokon statisztikai és feltáró vizsgálatok kerülnek elvégzésre az adatok közötti összefüggések feltárása érdekében. Ezt követően a dolgozat a gépi tanulás területére fókuszál, különös tekintettel az osztályozási problémák megoldására. A Python [7] programozási nyelv és annak gépi tanulást támogató könyvtárai segítségével különböző osztályozó algoritmusok kerülnek alkalmazásra és összehasonlításra.

A dolgozat célja annak bemutatása, hogy a megfelelő adat-előkészítés és -feldolgozás milyen mértékben befolyásolja a gépi tanulási modellek teljesítményét, valamint hogy az alkalmazott osztályozási módszerek mennyire hatékonyan alkalmazhatók videójáték-adatok elemzésében.

2. fejezet

Adatok előkészítése

Ebben a fejezetben a dolgozat során felhasznált adatok forrása és előkészítési folyamata kerül bemutatásra. A fejezet első része rövid áttekintést ad a Steam [1] szolgáltatásról, valamint az onnan származó, a Kaggle [2] platformon elérhető adathalmazok jellemzőiről, beleértve azok formátumát és mennyiségi tulajdonságait. Ezt követően a vizsgált adathalmazok részletesebb áttekintése történik meg, különös tekintettel az egyes adatkészletek külön notebookokban végzett elemzésére és az adatelőkészítés során szerzett gyakorlati tapasztalatokra.

2.1. Steam szolgáltatás és a kezelt adatai

A következő alfejezetek röviden bemutatják a Steam [1] szolgáltatást mint adatforrást, valamint a dolgozat során felhasznált adatok eredetét, elérhetőségét és alapvető jellemzőit. Emellett áttekintésre kerülnek az adatelőkészítés és elemzés során alkalmazott fejlesztőkörnyezetek és szoftveres eszközök is.

2.1.1. A Steam szolgáltatás áttekintése

A Steam [1] egy digitális videójáték-disztribúciós platform, amelyet a Valve Corporation [3] üzemeltet, és amely világszerte az egyik legnagyobb online videójáték-áruháznak számít. A szolgáltatás lehetőséget biztosít videójátékok vásárlására, letöltésére és frissítésére, valamint különböző közösségi funkciók – például értékelések, fórumok és statisztikák – elérésére.

A Steam platformon elérhető videójátékokhoz számos, nyilvánosan hozzáférhető adat kapcsolódik. Ezek közé tartoznak többek között a játékok alapvető jellemzői (például cím, megjelenési dátum, fejlesztő, kiadó), műfaji besorolásuk, felhasználói értékelések, valamint egyes esetekben teljesítményre és népszerűsége vonatkozó mutatók.

Az ilyen típusú adatok különösen alkalmasak statisztikai elemzésre és gépi tanulási módszerek alkalmazására.

A Steam által kezelt adatok mennyisége és sokfélesége miatt a platform gyakran szolgál adatforrásként kutatási és elemzési célokra. Korábbi vizsgálatok elemezték például a Steam-felhasználói értékelések jellemzőit és információtartalmát [4], a játékok népszerűségének előrejelezhetőségét a platformon elérhető metaadatok alapján [5], valamint a címkéken és műfajokon keresztül kirajzolódó szerkezeti mintázatokat is [6]. A játékokhoz kapcsolódó strukturált adatok ezért lehetőséget biztosítanak különböző mintázatok feltárására, például a műfajok közötti különbségek, a felhasználói értékelések alakulása vagy a játékok népszerűségének vizsgálata során. Ennek köszönhetően a Steamhez kapcsolódó adathalmazok jól illeszkednek adatfeldolgozási és gépi tanulási feladatok bemutatásához.

2.1.2. A Kaggle platform szerepe

A Kaggle [2] egy online adatmegosztó és adatverseny-platform, amely elsősorban adatkutatási és gépi tanulási feladatokhoz biztosít nyilvánosan elérhető adathalmazokat. A platformon a felhasználók különböző forrásokból származó, dokumentált adatállományokat oszthatnak meg, amelyek kutatási és oktatási célokra egyaránt felhasználhatók.

A dolgozat során alkalmazott adathalmazok a Kaggle platformon kerültek publikálásra, és Steamhez kapcsolódó, nyilvános adatok feldolgozott formáit tartalmazzák. A Kaggle egységes hozzáférést, verziókezelést és leírást biztosít az adatkészletekhez, ami megkönnyíti azok összehasonlítható és reprodukálható feldolgozását.

2.1.3. Az elemzés során használt eszközök

Az adatok feldolgozása és elemzése Python [7] programozási nyelv felhasználásával történt. A fejlesztéshez a Visual Studio Code [8] fejlesztőkörnyezet, valamint Jupyter Notebook [14] alapú munkafüzetek kerültek alkalmazásra, amelyek lehetővé tették az interaktív adatelemzést és az egyes lépések dokumentálását.

Az adatok kezeléséhez és előfeldolgozásához elsősorban a `pandas` [9] és `NumPy` [10] könyvtárak kerültek felhasználásra, míg a vizualizációk elkészítéséhez a `matplotlib` [11] és `seaborn` [12] csomagok szolgáltak alapul. A gépi tanulási és regressziós számítások során a `scikit-learn` [13] könyvtár egyes komponensei kerültek alkalmazásra.

2.1.4. Letöltés, formátum és mennyiségi jellemzők

A dolgozat során használt adatok a Kaggle [2] platformon elérhető, Steamhez [1] kapcsolódó nyilvános adathalmazokból származnak. Az adatkészletek manuális letöl-

téssel kerültek beszerzésre a Kaggle webes felületén keresztül, amelyhez felhasználói fiók megléte szükséges. A letöltött állományok tömörített formában voltak elérhetők, és kicsomagolást követően különálló adatfájlokat (CSV és JSON formátumú táblákat) tartalmaztak.

Az elsőként vizsgált adatkészlet a *Steam Store Games (Clean dataset)* [16], amely a továbbiakban *A adathalmazként* kerül hivatkozásra. Az adathalmaz a Steam áruházban elérhető videójátékok különböző jellemzőit tartalmazza, többek között műfaji besorolásokat, leírásokat, címkéket és becsült tulajdonosi adatokat. Az adatok a Steam Store és a SteamSpy [15] API-k felhasználásával kerültek összegyűjtésre, és elsősorban a 2019 májusáig megjelent játékokra vonatkoznak. Az A adathalmaz több, egymással logikailag összefüggő CSV fájlból áll, amelyek külön relációként értelmezhetők; ezek rekord- és attribútumszáma táblánként eltérő.

A második adathalmaz a Kaggle platformon *Steam Games Dataset* [17] néven elérhető, amely a továbbiakban *B adathalmazként* kerül megjelölésre. Az adathalmaz egyetlen, nagyméretű CSV/JSON alapú táblát tartalmaz, amely a Steam API és a SteamSpy szolgáltatás adatain alapul. A feltáró adatelemzés során a CSV formátum került alkalmazásra. A B adathalmaz összesen 111452 rekordot és 40 attribútumot tartalmaz.

A harmadik vizsgált adatkészlet a *Steam Games Dataset 2025* [18], amely a továbbiakban *C adathalmazként* kerül hivatkozásra. Az adathalmaz a Steam áruház weboldalának automatizált feldolgozásával, valamint a Steam API és a SteamSpy adatainak felhasználásával készült, és 2025 márciusáig bezárólag tartalmaz adatokat. Az adatok több CSV fájlban érhetők el, beleértve nyers és előfeldolgozott változatokat is, amelyek táblánként eltérő attribútumkészlettel rendelkeznek.

Az adatkészletek eltérő szerkezete, fájlformátuma és attribútumkészlete indokoltta tette az adatok előzetes tisztítását, normalizálását, valamint egy egységesített adatszerkezet kialakítását, amely a későbbi elemzési és gépi tanulási feladatok alapját képezi. A felhasznált adathalmazok főbb mennyiségi jellemzőit, táblánkénti bontásban, a 2.1 táblázat foglalja össze.

A továbbiakban az A, B és C adathalmazok neve egyúttal az adott adathalmazhoz tartozó fájlokat tartalmazó jegyzék nevét is jelenti, amiket a **data** jegyzékben tárolok.

Adathalmaz	Tábla	Rekordok száma	Attribútumok száma
A	steam.csv	27 075	18
A	steam_description_data.csv	27 334	4
A	steam_media_data.csv	27 332	5
A	steam_requirements_data.csv	27 319	6
A	steamspy_tag_data.csv	29 022	372
B	games.csv	111 452	40
C	games_march2025_cleaned.csv	89 618	47
C	games_march2025_full.csv	94 948	47
C	games_may2024_cleaned.csv	83 646	46
C	games_may2024_full.csv	87 806	46

2.1. táblázat. A felhasznált adathalmazok táblánkénti mennyiségi jellemzői

2.2. A vizsgálandó adathalmaz áttekintése

A vizsgált adathalmazok előzetes feltárása és elemzése különálló Jupyter [14] munkafüzetekben történt, adathalmazonként elkülönítve. Az A [16], B [17] és C [18] adathalmazokhoz tartozó elemzések a dolgozathoz mellékelt `notebooks/Dataset_Analyses` jegyzékben található `A.ipynb`, `B.ipynb` és `C.ipynb` munkafüzetekben kerültek feldolgozásra. Ez a felosztás lehetővé tette az egyes adatkészletek szerkezetének, tartalmának és sajátosságainak részletes megismerését, valamint az adatokra jellemző problémák korai azonosítását. A munkafüzetekből létrehozott egyes ábrák külön mentésre kerültek a `notebooks/generated/A`, `notebooks/generated/B` és `notebooks/generated/C` jegyzékekbe.


A külön munkafüzetek alkalmazása elősegítette a feldolgozási folyamat átláthatóságát, mivel az egyes adathalmazok eltérő szerkezettel, formátummal és attribútumkészlettel rendelkeztek. Ez a megközelítés lehetővé tette, hogy az adattisztítási, feltáró elemzési és előfeldolgozási lépések az adott adathalmaz sajátosságaihoz igazodjanak, anélkül hogy azok összekeveredtek volna más adatforrások feldolgozásával.

Az egyes adathalmazok esetében azonos alapvető vizsgálati lépések kerültek elvégzésre. Ezek célja az adatok általános állapotának felmérése, valamint a későbbi feldolgozási lépések megalapozása volt. A munkafüzetekben az alábbi vizsgálatok történtek meg:

- az adatok betöltése és szerkezetének áttekintése, beleértve az oszlopok számát, adattípusokat és a hiányzó értékek előfordulását,
- alapvető statisztikai leíró mutatók vizsgálata,
- a főbb attribútumok vizualizációja, például eloszlások, időbeli trendek és kategória-gyakoriságok megjelenítése,
- adatminőségi problémák, kiugró értékek és jellegzetes mintázatok azonosítása.

Az előzetes feltáró elemzés során néhány, az adathalmazok jellegét jól szemléltető vizualizáció is készült. Ezek célja nem a részletes statisztikai elemzés, hanem az adatok alapvető szerkezetének, eloszlásainak és időbeli mintázatainak bemutatása.

Az *A adathalmaz* esetében a játékok átlagos árának időbeli alakulását vizsgáltam. A 2.1 ábra az éves átlagárak változását mutatja. A töröttvonalas ábrázolás célja az egymást követő évek közötti változások áttekinthetőbb megjelenítése; a vonalszakaszok a közbülső értékek szemléletes közelítését adják, nem pedig ténylegesen megfigyelt adatpontokat jelölnek. Az ábra alapján hosszabb távú trendek és árszintváltozások azonosíthatók. Az eredmények arra utalnak, hogy az átlagár nem állandó, hanem az egyes időszakokban számottevő ingadozást mutat, ami a Steam platform üzleti modelljének és a megjelenő játékok összetételének változásával hozható összefüggésbe.



2.1. ábra. Az *A* adathalmazban szereplő játékok átlagos ára évenként


Szintén az *A adathalmaz*hoz kapcsolódóan a műfaji eloszlás vizsgálata is megtörtént. A 2.2 ábra a Top 20 műfaj előfordulási gyakoriságát szemlélteti. Jól látható, hogy néhány műfaj jelentős dominanciával rendelkezik, míg a ritkább kategóriák csak korlátozott számban jelennek meg. Ez a jelenség fontos szempont az adathalmaz későbbi

elemzésekor, mivel a műfajok közötti egyenlőtlen eloszlás torzíthat bizonyos statisztikai következtetéseket.




2.2. ábra. Az A adathalmaz Top 20 műfajának előfordulási gyakorisága

A *B adathalmaz* esetében a játékok által támogatott platformok szerinti megoszlás került vizsgálatra. A 2.3 ábra bemutatja, hogy a Windows platform támogatása messze domináns, míg a macOS és Linux rendszerek lényegesen kisebb arányban jelennek meg. Ez az eltérés jól szemlélteti a platformfüggetlenség korlátait, valamint magyarázatot adhat bizonyos platform-specifikus hiányosságokra az adatokban.



2.3. ábra. A B adathalmazban szereplő játékok száma támogatott platformonként

A *C adathalmaz* elemzése során a játékok Metacritic [19] értékeinek időbeli alakulása került előtérbe. A 2.4 ábra a Metacritic pontszámok és a kiadási év kapcsolatát ábrázolja. Az ábra alapján megfigyelhető, hogy az értékelések jelentős szórást mutatnak minden időszakban, ugyanakkor az idő előrehaladtával a pontszámok eloszlása kiegyensúlyozottabbá válik. Ez arra utal, hogy a modern időszakban a megjelenő játékok minősége stabilabb, illetve az értékelési mechanizmus egységesebbé vált.



2.4. ábra. A C adathalmazban szereplő játékok Metacritic értékei a kiadási év függvényében

A feltáró vizsgálatok során szerzett tapasztalatok rávilágítottak arra, hogy az adathalmazok közötti különbségek — például az eltérő attribútumnevek, hiányzó értékek és formátumbeli eltérések — jelentős hatással vannak a későbbi összevonási és normalizálási lépésekre. A kezdeti, elkülönített feldolgozás ezért kulcsszerepet játszott egy egységes, közös adatszerkezet kialakításának előkészítésében. Az itt bemutatott előzetes elemzések eredményei szolgáltak alapul a következő fejezetben részletezett adattisztítási, normalizálási és adathalmaz-összevonási folyamatokhoz.

3. fejezet

Adatok egységes struktúrába szervezése

Ebben a fejezetben a vizsgált adathalmazok egységes adatstruktúrába szervezésének folyamata kerül bemutatásra. A fejezet célja annak ismertetése, hogy a korábban elkülönítve feldolgozott, eltérő szerkezetű adatkészletek hogyan alakíthatók át egy közös, jól strukturált adatsémává, amely alkalmas további elemzési és gépi tanulási feladatok elvégzésére.

A fejezet első részében az adathalmazok közötti kapcsolatok és relációs sémák elemzése történik meg, amely alapot szolgáltat az adatok logikus felépítéséhez. Ezt követően bemutatásra kerülnek az alkalmazott normalizálási lépések, valamint azok indoklása az adatbázis-tervezési alapelvek figyelembevételével. Emellett ismertetésre kerülnek az adatok tisztításával kapcsolatos feladatok is, különös tekintettel a hiányzó és inkonzisztens értékek kezelésére. A fejezet további részében az egyes adathalmazok összevonásának (merge), valamint az egységesített adathalmaz normalizált résztáblákra bontásának folyamata kerül bemutatásra.

A fejezetben ismertetett lépések nem csupán elméleti adatmodellezési döntéseket jelentenek, hanem egy külön fejlesztett, moduláris felépítésű Python-alapú feldolgozórendszer konkrét műveleteihez kapcsolódnak. Az összefésülési feladatok a `merge` könyvtárban, míg az egységesített adatállomány normalizált résztáblákra bontása a `split` könyvtárban került megvalósításra. Mindkét feldolgozási szakasz a megfelelő `main.ipynb` munkafüzetből került végrehajtásra, amely a háttérben meghívja a szükséges Python modulokat és segédfüggvényeket.

3.1. Relációs sémák elemzése

Az adathalmazok egységes struktúrába szervezésének első lépéseként az egyes adatkészletek relációs sémáinak elemzése történt meg. A vizsgálat célja az volt, hogy feltárja az adatok belső szerkezetét, az attribútumok közötti kapcsolatokat, valamint azokat az azonosítókat, amelyek az adathalmazok későbbi összekapcsolását lehetővé teszik.

A feldolgozás során az A [16], B [17] és C [18] adathalmazokhoz külön relációs sémák kerültek kialakításra. Ezek a sémák az egyes adatkészletek logikai felépítését írják le, kiemelve a fő entitásokat, azok attribútumait, valamint az elsődleges és idegen kulcsokat. Az elkülönített sémák vizsgálata lehetővé tette az adathalmazok közötti hasonlóságok és szerkezeti eltérések azonosítását.

Az A adathalmaz relációs sémája a videójátékok alapvető jellemzőit tartalmazza, és referenciapontként szolgált a további adatkészletek integrálása során. A B és C adathalmazok sémái kiegészítő információkat hordoznak, amelyek eltérő attribútumkészlettel rendelkeznek, ugyanakkor közös játékaazonosítók mentén kapcsolhatók az A adathalmazhoz.

Az A, B és C adathalmazok sémáinak elemzését követően került kialakításra a D adathalmaz relációs sémája, amely az eredeti adatkészletek összevonásával létrehozott, egységes adatstruktúrát írja le. A D adathalmaz sémája már a normalizálási és tisztítási lépések eredményét tükrözi, és közvetlen alapját képezi a további elemzési és gépi tanulási feladatoknak.

A sémák elemzése során meghatározásra került az adathalmazok összevonásának prioritási sorrendje is. Az integrálás során a C adathalmaz szolgált elsődleges adatforrásként, mivel ez tartalmazta a legfrissebb információkat. A B, majd az A adathalmaz adatai kiegészítő jelleggel kerültek figyelembevételre, elsősorban azon attribútumok esetében, amelyek a C adathalmazban nem, vagy csak hiányosan álltak rendelkezésre. Ez a prioritási sorrend biztosította, hogy az összevont adathalmaz a lehető legaktuálisabb adatokat tükrözze.

A relációs sémák vizsgálata rávilágított arra, hogy az eltérő szerkezetű adathalmazok integrálása csak előzetes normalizálási és adatelőkészítési lépések után valósítható meg hatékonyan. A feltárt kapcsolatokat és függőségeket szolgálták alapul a következő alfejezetben bemutatott normalizálási folyamatokhoz, valamint az adathalmazok összevonásának megvalósításához.

3.2. Normalizálás

A normalizálás célja az adatredundancia csökkentése, az adatintegritás biztosítása, valamint az adatok logikus, karbantartható és bővíthető szerkezetbe rendezése. A dolgozat során alkalmazott normalizálási lépések az első, második és harmadik normálforma (1NF–3NF) követelményeit követik, figyelembe véve az egyes adathalmazok eltérő szerkezeti sajátosságait.

A bemutatott normalizálási döntések gyakorlati megvalósítása az egységesített adathalmaz előállítását követően, elsősorban a projekt `split` könyvtárában történt. A `split/main.ipynb` munkafüzet vezérli az egységesített `merged_master.csv` állomány feldolgozását, míg a normalizált relációk előállítását a `split/tables` alkönyvtár tematikusan szervezett moduljai végzik. Ezek a programrészek hozzák létre a fejezetben ismertetett entitásokat és kapcsolótáblákat, például a játékok metaadatait, a műfajokhoz, kategóriákhoz, platformokhoz, nyelvekhez, fejlesztőkhöz, kiadókhoz és címkekhez tartozó relációkat.

3.2.1. Az A adathalmaz normalizálása

Első normálforma (1NF)

Az eredeti CSV állomány több olyan attribútumot tartalmazott, amelyek nem atomi értékeket vettek fel. Ilyenek voltak például a több elemet tartalmazó címkek, műfajok, kategóriák, platformok, valamint a képernyőképeket és videókat leíró mezők. Az első normálforma követelménye szerint minden attribútumnak oszthatatlan, atomi értéket kell tartalmaznia, ezért ezek az összetett és listaértékű attribútumok külön táblákba kerültek.

A listaértékű adatok kezelésére külön entitások és kapcsolótáblák kerültek kialakításra. A címkek, műfajok, platformok és kategóriák önálló táblákban kerültek tárolásra, míg a játékok és ezen attribútumok közötti több-több kapcsolatokat kapcsolótáblák reprezentálják. Az A adathalmazban a címkek eredetileg több különálló oszlopban szerepeltek, amelyek a feldolgozás során egységes szerkezetbe kerültek összevonásra, és egy szótárjellegű (dictionary) struktúrában lettek eltárolva a további normalizálási lépések megkönnyítése érdekében.

A médiatartalmak – képernyőképek és videók – esetében minden egyes elem külön rekordként került eltárolásra. A képernyőképeket tartalmazó attribútumok további bontása is szükségessé vált, mivel az eredeti adathalmaz teljes méretű és előnézeti képeket egyetlen struktúrában tárolt. Ennek megfelelően a képernyőképek külön attribútumokra kerültek bontásra a teljes felbontású (*screenshots_full*) és az előnézeti (*screenshots_thumbs*) képek elkülönített kezelésére. Hasonló módon a videók esetében

külön attribútumok kerültek kialakításra az eltérő típusú és felbontású médiaforrások kezelésére (*movies_thumbnail*, *movies_max*, *movies_480*). A rendszerkövetelmények szintén felbontásra kerültek operációs rendszer és követelménytípus (minimum, ajánlott) szerint.

A rendszerkövetelmények esetében az eredeti, platformonként elkülönített mezők egységes struktúrába kerültek átszervezésre, ahol az operációs rendszer (*windows*, *mac*, *linux*) külön attribútumban jelenik meg. A követelmények típusa egy külön *type* mező segítségével került megkülönböztetésre, amely minimum és ajánlott értékeket vehet fel, míg a konkrét hardver- és szoftverkonfiguráció a *requirements* mezőben kerül tárolásra.

Második normálforma (2NF)

A második normálforma biztosítása érdekében vizsgálatra kerültek az elsődleges kulcs-tól való részleges függőségek. Az A adathalmaz központi táblája a *game* entitás, amelynek elsődleges kulcsa az *appid*. Azokat az attribútumokat, amelyek ugyan az *appid*-től függenek, de nem a játék alapadatait írják le, külön táblákba kerültek szétválasztásra.

Ennek eredményeként önálló táblák jöttek létre a részletes és rövid leírások kezelésére, a támogatási információk (például URL és e-mail cím) tárolására, valamint a médiához kapcsolódó elemek elkülönítésére. A rendszerkövetelmények kezelése szintén külön táblában történt, az operációs rendszer és a követelménytípus figyelembevételével.

Harmadik normálforma (3NF)

A harmadik normálforma megvalósítása során a tranzitív függőségek megszüntetésére került sor. A fejlesztők és kiadók adatai önálló entitásokba kerültek, és a játékokhoz kapcsolótáblákon keresztül kapcsolódnak. Ez a megoldás lehetővé tette a redundáns szöveges adatok elkerülését és az adatok konzisztens kezelését. Az adathalmazban szereplő fejlesztőkre és kiadókra vonatkozó attribútumok elnevezései az eredeti struktúrát követték (*developer*, *publisher*), azonban a normalizált sémában ezek önálló entitásokként jelennek meg, biztosítva az egységes elnevezést és a redundancia mentes adatkezelést.

Hasonló módon a kategóriák, műfajok, címkék és platformok esetében is külön táblák tárolják az egyedi értékeket, míg a játékokkal való kapcsolatukat kizárólag azonosítók segítségével megvalósított kapcsolótáblák reprezentálják. A több-több kapcsolatok minden esetben explicit módon, kapcsolótáblák segítségével kerültek kezelésre.

Összegzés

A normalizálási folyamat eredményeként az A adathalmaz [16] relációs sémája több, logikailag elkülönülő entitásból épül fel. A központi *game* tábla mellett önálló táblák jöttek létre a leírások, támogatási információk, médiatartalmak, rendszerkövetelmények, valamint a különböző kategorizáló attribútumok kezelésére. A sémában minden több–több kapcsolat külön kapcsolótáblán keresztül valósul meg, biztosítva az adatok redundanciamentes tárolását.

Az A adathalmaz normalizálási lépései biztosították az adatredundancia minimalizálását, a tranzitív függőségek megszüntetését, valamint a listaértékű és összetett attribútumok önálló táblákba történő szétválasztását. A kialakított relációs séma jól strukturált, karbantartható és alkalmas arra, hogy alapjául szolgáljon a további adatintegrációs és gépi tanulási feladatoknak.

Az A adathalmaz részletes attribútumleírását és az egyes mezők jelentését tartalmazó adatleíró (data dictionary) a projekt `doc/Dictionaryes` könyvtárában található `A_schema_data_dictionary.xlsx` állományban érhető el. Az A adathalmaz normalizálatlan relációs sémája a függelék A.1. ábráján, míg a normalizált relációs sémája a függelék A.2. ábráján látható. A *tags* tábla esetében az eredeti adathalmaz rendkívül nagyszámú, bináris címkeattribútumot tartalmaz, ezért ezek teljes felsorolása terjedelmi okokból nem jelenik meg az ábrán; a sémadiagram elsősorban az adatszerkezet logikai felépítését szemlélteti, nem az összes konkrét címkét.

3.2.2. A B adathalmaz normalizálása

Első normálforma (1NF)

Az eredeti *games.csv* állomány több ismétlődő és listaértékű attribútumot tartalmazott, például képernyőképeket, címkéket, kategóriákat, műfajokat, támogatott nyelveket, szinkronhangokat és játékcsomagokat. Az első normálforma követelményeinek megfelelően ezek az attribútumok felbontásra kerültek, és az adatok atomi értékeket tartalmazó táblákba lettek átszervezve.

A médiatartalmak – képek és videók – külön táblákban kerültek tárolásra, ahol minden elem önálló rekordot képez. A kategóriák, műfajok és címkék esetében önálló entitások jöttek létre, míg a játékokkal való több–több kapcsolatukat kapcsolótáblák reprezentálják. A nyelvek külön táblában kerültek eltárolásra, és a játékokhoz való kapcsolódásuk felirat és szinkronhang szerinti bontásban történt. A platformok kezelése szintén normalizált formában, külön táblák és kapcsolatok segítségével valósult meg.

A játékcsomagok összetett szerkezete miatt többszintű modell került kialakításra, amely elkülöníti a csomag alapadatait és azok alelemeit, biztosítva az adatok áttekint-

hető és atomi szintű tárolását.

Második normálforma (2NF)

A második normálforma biztosítása érdekében a részleges függőségek megszüntetésére került sor. A központi *game* tábla elsődleges kulcsa az *appid*, amelyhez kizárólag a játék alapadatai tartoznak. Azok az attribútumok, amelyek nem közvetlenül a játék leírását szolgálják, külön relációkba kerültek.

Ennek eredményeként önálló táblák jöttek létre a támogatási információk, média-tartalmak, kategorizáló attribútumok, nyelvek, fejlesztők, kiadók, platformok és csomagadatok kezelésére. A több-több kapcsolatok minden esetben asszociatív táblák segítségével kerültek megvalósításra, biztosítva az adatok egyértelmű és redundancia-mentes összekapcsolását.

Harmadik normálforma (3NF)

A harmadik normálforma megvalósítása során a tranzitív függőségek megszüntetése volt a cél. A címkék, műfajok, nyelvek, fejlesztők, kiadók, kategóriák, platformok és csomagok megnevezései önálló táblákban kerültek eltárolásra, így elkerülhetővé vált a redundáns szöveges adatok ismétlődése.

A nyelvek kezelése egységes módon történt, ahol az egyes nyelvek egyszer kerülnek tárolásra, és külön kapcsolótáblák jelzik, hogy egy adott játék rendelkezik-e feliratokkal vagy hanggal az adott nyelven. Ez a megoldás megszüntette a korábbi listaértékű mezők közötti redundanciát. A játékcsomagok többszintű felépítése szintén a tranzitív függőségek elkerülését és az adatok logikus strukturálását szolgálta.

Összegzés

A normalizálás eredményeként a B [17] adathalmaz relációs sémája egy jól strukturált, több entitásból álló adatmodellt alkot. A központi *game* tábla mellett önálló relációk kezelik a támogatási információkat, médiatartalmakat, kategorizáló attribútumokat, nyelveket, fejlesztőket, kiadókat, platformokat, valamint a játékcsomagok és azok al-elemeinek adatait. A séma minden több-több kapcsolatot külön kapcsolótáblákon keresztül valósít meg.

A B adathalmaz normalizálási folyamata eredményeként egy tiszta, jól strukturált adatmodell jött létre, amely megfelel az első három normálforma követelményeinek. A kialakított séma atomi értékeket tartalmaz, megszünteti a részleges és tranzitív függőségeket, valamint külön táblákban kezeli az összetett és listaértékű mezőket. Az alkalmazott struktúra jól bővíthető, karbantartható, és minimális adatredundanciát biztosít

a további feldolgozási és elemzési lépésekhez.

A B adathalmaz normalizált sémájához tartozó adatleíró (data dictionary), amely az attribútumok jelentését és típusát részletezi, a projekt `doc/Dictionaryes` könyvtárban található `B_schema_data_dictionary.xlsx` állományban érhető el. A B adathalmaz normalizálatlan relációs sémája a függelék A.3. ábráján, míg a normalizált relációs sémája a függelék A.4. ábráján látható.

3.2.3. A C adathalmaz normalizálása

A C [18] adathalmaz normalizálásának kiindulópontját négy, időben és feldolgozottságban eltérő CSV-fájl képezte: a 2024 májusi és a 2025 márciusi adatállományok nyers (*full*) és előfeldolgozott (*cleaned*) változatai. A *full* állományok a Steam [1] áruházból származó teljes, nyers adatokat tartalmazták, míg a *cleaned* változatok már előzetes tisztításon átesett, duplikációktól mentes adatokat biztosítottak.

A 2025-ös adatkészletek a korábbi verziókhoz képest egy további attribútummal is bővültek, amely a játékok aktuális kedvezményét (*discount*) írja le. A normalizálás során az eltérő időpontokból és szerkezetből adódó különbségek egységes kezelése kiemelt szempont volt.

Első normálforma (1NF)

Az eredeti CSV-fájlok több olyan attribútumot tartalmaztak, amelyek nem atomi értékeket vettek fel. Ilyenek voltak például a képernyőképek, címkék, kategóriák, műfajok, valamint a támogatott feliratokat és szinkronhangokat tartalmazó mezők. Az első normálforma követelményeinek megfelelően ezek az összetett és listaértékű attribútumok külön relációkba kerültek.

A normalizálás során önálló entitások jöttek létre többek között a médiatartalmak, képernyőképek, videók, leírások, kategóriák, műfajok, nyelvek, platformok és játékcsomagok kezelésére. A nyelvi attribútumok két külön relációban kerültek eltárolásra, megkülönböztetve a feliratokat és a szinkronhangokat. Ez a felosztás lehetővé tette a nyelvi támogatás pontosabb és redundanciamentes kezelését.

Második normálforma (2NF)

A második normálforma biztosítása érdekében a részleges függőségek megszüntetésére került sor. A játékokat leíró központi tábla elsődleges kulcsa az *appid*, amelyhez kizárólag a játék alapadatai tartoznak. Azok az attribútumok, amelyek ugyan az *appid*-től függenek, de nem közvetlenül a játék alapjellemzőit írják le, külön relációkba kerültek.

Önálló táblák jöttek létre többek között a támogatási információk, médiatartalmak, leírások, kategóriák, műfajok, nyelvek, fejlesztők, kiadók, címkék, platformok és játéksomagok kezelésére. A redundáns szöveges ismétlődések megszüntetésre kerültek azáltal, hogy az egyes entitások megnevezései saját táblákban szerepelnek, míg a játékokkal való kapcsolatukat kizárólag azonosítók biztosítják.

Harmadik normálforma (3NF)

A harmadik normálforma megvalósítása során a tranzitív függőségek megszüntetése volt a cél. A kategóriák, műfajok, nyelvek, fejlesztők, kiadók, címkék, platformok és csomagok megnevezései önálló entitásokban kerültek eltárolásra, míg a játékokkal való kapcsolatukat külön asszociatív táblák írják le.

A játéksomagok kezelése háromszintű struktúrában valósult meg. A játék és a csomag közötti kapcsolatot egy kapcsolótábla reprezentálja, míg a csomagok alapadatai és azok alemei külön relációkban kerültek eltárolásra. Ez a megoldás biztosítja az összetett csomagstruktúrák áttekinthető és redundanciamentes kezelését.

Összegzés

A normalizálás eredményeként a C adathalmaz relációs sémája egy egységes, jól strukturált adatmodellt alkot. A központi *game* tábla mellett önálló relációk kezelik a támogatási információkat, médiatartalmakat, leírásokat, kategorizáló attribútumokat, nyelveket, fejlesztőket, kiadókat, platformokat, valamint a játéksomagok és azok alemeinek adatait. A 2025-ös adatkészletekben megjelenő *discount* attribútum a végső sémában is elkülönítve, konzisztens módon került kezelésre.

A C adathalmaz normalizálása során négy különálló, eltérő időpontból származó CSV-fájl került egységes relációs struktúrába szervezésre. Az alkalmazott normalizálási lépések biztosítják az első három normálforma követelményeinek teljesülését, elkülönítik a felirat- és hangnyelveket, valamint strukturált módon kezelik a játéksomagokat. A kialakított séma csökkenti az adatredundanciát, elősegíti az adatok konzisztenciáját, és rugalmasan kezeli a 2024-es és 2025-ös adatforrások közötti eltéréseket, így megfelelő alapot biztosít a további integrációs és elemzési feladatokhoz.

A C adathalmaz normalizált sémájához tartozó adatleíró (data dictionary), amely az egyes attribútumok jelentését és típusát részletezi, a projekt `doc/Dictionaryes` könyvtárában található `C_schema_data_dictionary.xlsx` állományban érhető el. A C adathalmaz normalizálatlan relációs sémája a függelék A.5. ábráján, míg a normalizált relációs sémája a függelék A.6. ábráján látható.

3.2.4. A D adathalmaz normalizálása

A D adathalmaz egységes relációs sémája az A [16], B [17] és C [18] adathalmazok összevonásával és strukturális egységesítésével jött létre. Kiindulási alapként több, eltérő forrásból származó CSV-fájl szolgált, amelyek részben különböző szerkezettel, eltérő attribútumkészlettel és eltérő időpontokból származó adatokat tartalmaztak. A normalizálás célja egy olyan konzisztens, redundanciamentes adatmodell kialakítása volt, amely egységesen kezeli az eltérő forrásokból származó információkat.

A 2024-es és 2025-ös adatkészletek közötti egyik lényeges eltérés, hogy a 2025-ös verziók egy további attribútumot is tartalmaztak, amely a játékok aktuális kedvezményét (*discount*) írja le. Az egységesítés során ezek a forrásbeli különbségek kezelhető módon kerültek beépítésre a végső sémába.

Első normálforma (1NF)

Az összevont CSV-fájlok több olyan attribútumot tartalmaztak, amelyek nem atomi értékeket vettek fel, például címkéket, műfajokat, kategóriákat, támogatott nyelveket, hangnyelveket, csomagstruktúrákat és rendszerkövetelményeket JSON formátumban. Az első normálforma követelményeinek megfelelően ezek az összetett és listaértékű mezők önálló relációkba kerültek.

Az ilyen attribútumok kezelésére külön entitások és kapcsolótáblák jöttek létre, amelyek a játékokkal való kapcsolatot asszociatív módon írják le. Ide tartoznak többek között a felirat és szinkronhangok kezelése, a címkék, műfajok, kategóriák, platformok, valamint a többszintű csomagszerkezetek és a rendszerkövetelmények strukturált tárolása. Ez a felbontás biztosítja, hogy minden attribútum atomi értéket vegyen fel, és megfeleljen az első normálforma előírásainak.

Második normálforma (2NF)

A második normálforma megvalósítása érdekében a részleges függőségek megszüntetésére került sor. A D adathalmaz központi táblája a *game* entitás, amelynek elsődleges kulcsa az *appid*. Azok az attribútumok, amelyek az *appid*-től függnak, de nem a játék alapadatait írják le, külön relációkba kerültek.

Ennek eredményeként önálló táblák jöttek létre többek között a leírások, támogatási információk, médiatartalmak, képernyőképek, videók, rendszerkövetelmények, nyelvek, tulajdonosi tartományok, valamint a csomagok és azok alelemeinek kezelésére. Ez a szétválasztás biztosítja, hogy minden nem kulcsattribútum teljes mértékben függjön az elsődleges kulcstól.

Harmadik normálforma (3NF)

A harmadik normálforma teljesítése érdekében a tranzitív függőségek megszüntetésre kerültek. Az ismétlődő szöveges attribútumok – például címkék, műfajok, kategóriák, nyelvek, platformok, fejlesztők és kiadók – önálló entitásokban kerültek eltárolásra, míg a játékokkal való kapcsolatukat külön asszociatív táblák reprezentálják.


A több-több kapcsolatok minden esetben kapcsolótáblák segítségével kerülnek kezelésre, biztosítva az adatok konzisztenciáját és a redundancia minimalizálását. A játékcsomagok kezelése háromszintű struktúrában valósult meg, amely elkülöníti a játék-csomag kapcsolatot, a csomag alapadatait és a csomagok alelemeit. Ez a megoldás lehetővé teszi az összetett csomagszerkezetek áttekinthető és bővíthető kezelését.

Összegzés

A D adathalmaz relációs sémája az A, B és C adathalmazok összevonásával létrehozott, egységes adatmodellt képvisel. A kialakított struktúra biztosítja az első három normálforma követelményeinek teljesülését, megszünteti a redundáns és nem atomi mezőket, valamint strukturált módon kezeli a több-több kapcsolatokat és az összetett csomagstruktúrákat. A séma képes kezelni az eltérő adatforrások közötti különbségeket, bővíthető a jövőbeni adatokkal, és stabil alapot biztosít a további elemzési és gépi tanulási feladatokhoz.

A D adathalmaz részletes attribútumleírását és az egyes mezők jelentését tartalmazó adatleíró (data dictionary) a projekt `doc/Dictionaryes` könyvtárában található `D_schema_data_dictionary.xlsx`

A D adathalmaz normalizált relációs sémájának SQL-alapú megvalósítása a dolgozat mellékleteiben található, a `doc/db` jegyzéken belül. Az ott bemutatott SQL definíciók a végső adatmodellt írják le, és egyértelműen jelölik, hogy az egyes táblák és attribútumok mely forrásadathalmazokból (A, B vagy C) származnak. A D adathalmaz egységesített, normalizált relációs sémája a 3.1 ábrán látható.



3.1. ábra. A D adathalmaz egységes, normalizált relációs sémája


3.3. Adathalmazok összefésülése

Ebben az alfejezetben az A [16], B [17] és C [18] adathalmazok összefésülésének folyamata kerül bemutatásra. Az adathalmazok egyesítése során az eltérő forrásokból származó adatok strukturális különbségeinek kezelése, az attribútumok egységesítése, valamint az adatok konzisztenciájának biztosítása volt a fő cél. Az összefésülési folyamat eredményeként jött létre a végső, egységes D adathalmaz, amely a további elemzések alapját képezi.

Az alfejezet bemutatja az adathalmazok összefésülésének logikai lépéseit, a folyamat vizuális áttekintését, valamint a megvalósításhoz használt módszereket. Emellett kitér a merge során végrehajtott ellenőrzésekre és azokra a döntésekre, amelyek biztosították az adatok helyes és következetes integrációját.

3.3.1. Az összefésülés logikai folyamata

Az adathalmazok összefésülésének folyamata az A [16], B [17] és C [18] forrásadatok strukturált és kontrollált egyesítését mutatja be. A folyamat célja egy egységes, konzisztens adatmodell létrehozása volt, amely a különböző forrásokból származó információkat egységes szerkezetben tartalmazza. Az összefésülés lépéseit és azok egymásra épülését a 3.2 ábra szemlélteti.



3.2. ábra. Az A, B és C adathalmazok összefésülésének folyamata

Az ábra PlantUML [20] alapú forráskódja külön fájlban is elérhető (`doc/Merge_process_diagram/merge.puml`), amely a folyamat reprodukálhatóságát és dokumentáltságát biztosítja.

Az összefésülés lépései

Az 3.2 ábrán bemutatott folyamat három fő részlépésből áll, amelyek során az egyes forrásadathalmazok önállóan kerülnek feldolgozásra és előkészítésre az egységesítés előtt.

Első lépésként a C forrás feldolgozása történik meg, amely során a 2024-es és 2025-ös CSV-fájlok kerülnek összevonásra és előtisztításra. Ennek eredményeként jön létre a `C_combined.csv` állomány, amely már egységes szerkezetben tartalmazza az időben eltérő adatforrások adatait.

Második lépésként a B forrás feldolgozása következik, ahol a JSON formátumban elérhető SteamSpy [15] adatok normalizálása és táblásítása történik meg. A feldolgozás eredményeként a `B_full.csv` állomány jön létre, amely strukturált formában tartalmazza a másodlagos adatforrásból származó információkat.

Harmadik lépésként az A forrás feldolgozása valósul meg, amely során a több CSV-fájlból álló Steam-metaadatok belső összevonása történik meg. Az eredmény az `A_merged.csv` állomány, amely az A adathalmaz egységesített változatát tartalmazza.

Források egyesítése és prioritási sorrend

Az előfeldolgozott részadathalmazok ezt követően egyesítésre kerülnek egy közös adatállományba. Az összefésülés során meghatározott prioritási sorrend biztosítja, hogy az eltérő források közötti átfedések esetén a legaktuálisabb és legmegbízhatóbb adatok kerüljenek felhasználásra.

A prioritási sorrend az alábbiak szerint alakult:

- a C adathalmaz elsődleges forrásként szolgált,
- a B adathalmaz másodlagos forrásként került bevonásra,
- az A adathalmaz kiegészítő, kitöltő szerepet töltött be.

A folyamat eredményeként egy egységes relációs struktúra jött létre (`merged_master.csv`), amely már közvetlenül alkalmas volt a normalizálási lépések végrehajtására és az SQL-alapú adatbázis felépítésére.

3.3.2. Az összefésülés megvalósítása

Ebben az alfejezetben az A [16], B [17] és C [18] adathalmazok összefésülésének szoftveres megvalósítása kerül bemutatásra. A merge-folyamat egy moduláris felépítésű Py-

thon [7] projektként valósult meg, amely külön kezeli a forrásadatok betöltését, az előfeldolgozási és tisztítási lépéseket, valamint az adatok egységesítését és ellenőrzését. A bemutatott kódrészletek nem a teljes implementációt fedik le, hanem az összefésülési folyamat szempontjából lényeges, nem triviális megoldásokat szemléltetik.

A merge-kód felépítése

Az adathalmazok összefésülése egy külön **merge** könyvtárban megvalósított, moduláris Python-alapú feldolgozórendszerrel történt. A folyamat belépési pontja a `merge/main.ipynb` munkafüzet, amely a teljes merge-folyamatot vezérli, és a háttérben a szükséges Python modulokat hívja meg. A globális paraméterezést a `merge/config.py` állomány tartalmazza.

A forrásadathalmazok beolvasását és előzetes feldolgozását a `merge/sources` al-könyvtár moduljai végzik (`source_a.py`, `source_b.py`, `source_c.py`), míg az általános adatkezelési, tisztítási, normalizálási és egyesítési segédfüggvények a `merge/utils` könyvtárban kaptak helyet. Az összefésülés eredményei és köztes kimenetei a `merge/generated` könyvtárba kerülnek mentésre, beleértve a részforrásokból előállított `A_merged.csv`, `B_full.csv`, `C_full.csv` állományokat, valamint a végső `merged_master.csv` táblát is. A folyamat során készült naplófájlok, jelentések és vizualizációk szintén itt kerülnek eltárolásra.

Kiemelt kódrészletek

A teljes kódbázis részletes ismertetése nem szükséges, ezért az alábbiakban csak néhány olyan megoldás kerül bemutatásra, amelyek jól szemléltetik az összefésülés során alkalmazott logikai döntéseket és adatkezelési stratégiákat. A projekt minden modula és függvénye részletes dokumentációval (docstringekkel) van ellátva.

Hiányzó adatok kitöltése forrásprioritás alapján A merge egyik kulcseleme egy olyan függvény (3.1), amely a céladatkészlet hiányzó mezőit más forrásokból pótolja. A kitöltés az *appid* alapján történik, és kizárólag azokat az oszlopokat érinti, amelyek mindkét adathalmazban megtalálhatók. A megoldás biztosítja, hogy a források közötti prioritás ($C \rightarrow B \rightarrow A$) ütközésmentesen érvényesüljön.

```
def fill_missing_from_source(d: pd.DataFrame,
                             src: pd.DataFrame) -> pd.DataFrame:
    src = src.copy()
    src["appid"] = src["appid"].astype(str)

    common_cols = [col for col in src.columns if col in d.columns]

    merged = d.merge(
```

```

    src[common_cols],
    on="appid",
    how="left",
    suffixes=("", "_src")
)

for col in common_cols:
    if col != "appid":
        merged[col] = merged[col].combine_first(merged[f"{col}_src"])
        merged.drop(columns=[f"{col}_src"], inplace=True)

return merged

```

3.1. Kódpélda. Hiányzó adatok pótlása

Listaértékű attribútumok egyesítése A címkék, műfajok, kategóriák és platformok esetében gyakori volt, hogy ugyanazon játékhoz több forrásból is listaértékű adatok tartoztak. Ezek összevonására egy deduplikáló segédfüggvény (3.2) került alkalmazásra, amely a különböző forrásokból származó listákat egyesíti, miközben az ismétlődő elemeket eltávolítja.

```

def dedup_join(*lists):
    combined = []
    for lst in lists:
        if isinstance(lst, list):
            combined.extend(lst)
    return list(dict.fromkeys(combined))

```

3.2. Kódpélda. Deduplikáló segédfüggvény

Képernyőképek több forrásból történő kombinálása A képernyőképek kezelése során az A, B és C adathalmazokból származó adatok egyesítése index-alapú lekérdezéssel történt. A megoldás lehetővé tette, hogy a különböző forrásokból származó képernyőképek a prioritási sorrendnek megfelelően kerüljenek összefűzésre, miközben az egységes attribútumstruktúra megmaradt.

Nyelvi mezők többlepcsős tisztítása A nyelvi mezők feldolgozása az egyik legösszetettebb lépés volt, mivel az A, B és C forrásokban eltérő, gyakran zajos formátumban jelentek meg. A normalizálás két egymásra épülő tisztítási lépésből állt: az első lépés a nyers adatok egységesítését és alapvető tisztítását végezte el, míg a második lépés a nyelvnevek szabványosítását és a kontextusfüggő hibák kiszűrését valósította meg. A folyamat eredményeként egy konzisztens, relációs adatbázisba illeszthető nyelvlista jött létre.

A B forrás JSON állományainak feldolgozása A B adathalmaz JSON formátumú, beágyazott szerkezete miatt külön betöltési és feldolgozási logika készült. A feldolgozás során az egyes játékokhoz tartozó mezők strukturált rekordokká alakultak, a listaértékű attribútumok normalizált formában kerültek eltárolásra, majd az adatok egységes Pandas DataFrame struktúrába rendeződtek. A feldolgozás fő lépéseit a 3.3 kódrészlet mutatja be.

```
def load_source_b(base_path: str) -> pd.DataFrame:
    file_path = os.path.join(base_path, "games.json")
    with open(file_path, "r", encoding="utf-8") as f:
        dataset = json.load(f)

    records = []
    for appID, game in dataset.items():
        fields = ["name", "release_date", "estimated_owners", "price"]
        record = {key: game.get(key) for key in fields}
        record["appid"] = str(appID)

        list_fields = ["packages", "developers", "publishers", "genres"]
        record.update({f: game.get(f, []) for f in list_fields})

        tags = game.get("tags", {})
        record["tags"] = tags if isinstance(tags, dict) else {}

        records.append(record)

    df_b = pd.DataFrame(records)
    df_b["release_date"] = pd.to_datetime(df_b["release_date"],
        errors="coerce")
```

3.3. Kódpélda. B adathalmaz feldolgozása

Logolás és ellenőrzés a merge folyamat során

Az összefésülési folyamat teljes egészében részletes naplózással került végrehajtásra. Ez lehetővé tette a forrásfájlok betöltésének, a feldolgozott rekordok számának, valamint az egyes tisztítási és összefésülési lépések nyomon követését. A naplóállományok segítségével a teljes feldolgozási folyamat visszakövethetővé vált, és az esetleges hibák vagy inkonzisztenciák gyorsan azonosíthatók voltak.

A részletes futási információk, figyelmeztetések és státuszüzenetek a `merge/generated/logs/merge_log.txt` állományban kerülnek rögzítésre, amely lehetővé teszi a feldolgozási lépések utólagos ellenőrzését és visszakövetését.

A naplózás kiterjedt többek között a forrásadatok betöltésére, az ideiglenes részadathalmazok mentésére, az adatok egyesítésére, valamint a végső, egységes D adathalmaz előállítására. Ez a megközelítés biztosította a merge-folyamat átláthatóságát és reprodukálhatóságát.

3.4. Az egységesített adathalmaz felbontása

A fejezetben ismertetett normalizált relációs struktúra gyakorlati előállítását a `split` könyvtárban megvalósított programrész végzi. A feldolgozás belépési pontja a `split/main.ipynb` munkafüzet, amely az egységesített `merged_master.csv` állományból kiindulva meghívja a normalizált táblák előállításáért felelős modulokat. Az egyes relációk létrehozása a `split/tables` könyvtár tematikus programrészeiben történik, így a normalizálási döntések közvetlenül konkrét, végrehajtható függvényekhez és modulokhoz kapcsolódnak.

A `split/tables` alkönyvtár moduljai funkcionális bontásban valósítják meg a relációk létrehozását. A `game_metadata.py` a játékok alapadataihoz és leírásaihoz tartozó táblákat állítja elő, a `media_tables.py` a médiatartalmakhoz kapcsolódó relációkat kezeli, a `genre_category_tables.py`, `platforms_tables.py` és `tags_tables.py` a kategorizáló attribútumokhoz tartozó entitásokat és kapcsolótáblákat generálja, míg a `language_tables.py`, `developer_publisher_tables.py`, `package_tables.py`, `requirements_tables.py` és `support_tables.py` az adott szakterületekhez tartozó normalizált táblák előállítását végzik.

Az összefésülési folyamat eredményeként létrejött `merged_master.csv` egyetlen, nagyméretű, összevont adatállományt tartalmazott. A `split` folyamat célja az volt, hogy ebből az egységesített táblából tematikus, normalizált CSV-fájlok jöjjenek létre, amelyek közvetlenül megfelelnek a kialakított relációs adatmodell struktúrájának.

A kód futása közben részletes naplózás készült, amely a `split/generated/logs/split_log.txt` állományban rögzíti a feldolgozás egyes lépéseit, biztosítva a folyamat átláthatóságát és visszakövethetőségét.

3.4.1. A `split` folyamat lépései

A teljes felosztási folyamatot a `split/main.ipynb` munkafüzet vezérli, amely az alábbi fő lépéseket hajtja végre:

- a `merged_master.csv` állomány betöltése,
- az egyes relációknak megfelelő résztáblák létrehozása,
- a generált táblák mentése CSV formátumban,
- a folyamat közben a feldolgozási lépések naplózása.

3.4.2. A létrehozott táblák

A `split` folyamat során az alábbi CSV-fájlok kerülnek előállításra:

- *game.csv* – a videójátékok alapadatai,
- *description.csv* – részletes, rövid és „about” leírások,
- *media.csv* – fejléc- és háttérképek,
- *screenshots.csv* – teljes méretű és előnézeti képernyőképek,
- *movies.csv* – videók (Full HD, 480p és előnézeti változatok),
- *support.csv* – támogatási URL-ek és e-mail címek,
- *requirements.csv* – minimum és ajánlott rendszerkövetelmények operációs rendszer szerint,
- *platforms.csv* és *game_platform.csv* – platformok és kapcsolótábla,
- *genres.csv* és *game_genre.csv* – műfajok és kapcsolótábla,
- *categories.csv* és *game_category.csv* – kategóriák és kapcsolótábla,
- *packages.csv*, *sub_package.csv* és *game_package.csv* – Steam csomagok és kapcsolatok,
- *developers.csv* és *game_developer.csv* – fejlesztők,
- *publishers.csv* és *game_publisher.csv* – kiadók,
- *tags.csv* és *game_tag.csv* – címkék és súlyozásuk,
- *languages.csv* – normalizált nyelvlista,
- *game_subtitles.csv* és *game_audio_language.csv* – felirat- és hangnyelvek.

3.4.3. A split folyamat működési elvei

A résztáblák előállításánál minden feldolgozási lépés azonos alapelveket követett. A *master* táblából kizárólag az adott relációhoz tartozó oszlopok kerültek kiválasztásra, a listaértékű mezők normalizálása megtörtént, és szükség esetén új azonosítók kerültek generálásra (például műfajok, címkék vagy nyelvek esetében). A több-több kapcsolatok kezelésére minden esetben külön kapcsolótáblák jöttek létre.

A split folyamat eredményeként az eredetileg egyetlen, összevont adatállományból olyan, logikailag elkülönített és normalizált táblák jöttek létre, amelyek teljes mértékben megfelelnek a relációs adatbázis-tervezési elveknek, és közvetlenül alkalmasak SQL-alapú adatbázisba történő importálásra.

4. fejezet

Leíró statisztikák

Ez a fejezet a korábbi fejezetekben előállított, egységesített *merged* adathalmazra épül, amely a különböző forrásokból származó videójáték-metaadatok összefésült és normalizált nézetét tartalmazza. Az adat-előkészítési, összevonási és felbontási lépések eredményeként létrejött adatállomány lehetővé teszi a Steam [1] platformon megjelenő videójátékok jellemzőinek átfogó, statisztikai szemléletű vizsgálatát.

A fejezet célja az adatok alapvető szerkezeti és mennyiségi tulajdonságainak feltárása, valamint a legfontosabb mintázatok és tendenciák bemutatása leíró statisztikai eszközök segítségével. Az elemzések nem prediktív jellegűek, hanem az adathalmaz megértését, konzisztenciájának ellenőrzését és a későbbi gépi tanulási feladatok előkészítését szolgálják.


A fejezet első alfejezete az előzetes vizsgálatokra fókuszál, amelyek során az adatok alapvető eloszlásai, időbeli lefedettsége és főbb numerikus jellemzői kerülnek áttekintésre. Ezt követően a grafikonokra épülő alfejezet vizuális eszközök segítségével mutatja be a játékmegjelenések, értékelések és egyéb kulcsfontosságú attribútumok közötti összefüggéseket és trendeket.

4.1. Előzetes vizsgálatok

Az előzetes vizsgálatok célja a *merged* adathalmaz szerkezetének és alapvető minőségi jellemzőinek áttekintése. Ebben a részben a források közötti átfedések mértékét, a rekordok forrás szerinti megoszlását, valamint az összevonás során releváns integrációs problémákat ellenőrzöm, amelyek közvetlenül befolyásolják a későbbi statisztikai elemzések és adatbázisba importálás megbízhatóságát.

4.1.1. Források közötti átfedések – Venn-diagram

Az A [16], B [17] és C [18] forrásadatok közötti átfedések vizsgálatához Venn-diagram készült, amely az *appid* azonosítók alapján szemlélteti, hogy mely rekordok érhetők el kizárólag egy adott adatforrásban, illetve melyek jelennek meg több forrás metszetében. A vizsgálat célja annak ellenőrzése volt, hogy az összevonás során mekkora a források közötti lefedettség, valamint milyen mértékű kiegészítő információ várható az egyes adathalmazoktól.



4.1. ábra. Az A, B és C források közötti átfedések Venn-diagramja *appid* alapján

A 4.1 ábrán látható, hogy a források közötti legnagyobb átfedés a B és C adathalmazok között figyelhető meg (79 888 közös *appid*), míg az A adathalmaz jellemzően a B forrással fed át (24 433 közös *appid*). Az egyedi rekordok száma a B és C források esetében alacsonyabb (5 731 csak B-ben, 161 csak C-ben), míg az A forrás különálló elemei (1 234) és az A–C közös, de B-ben nem szereplő rekordok (1 400) kisebb részarányt képviselnek. A diagram alapján megállapítható, hogy a D adathalmaz kialakítása során a B és C forrás együttes használata biztosítja a legnagyobb lefedettséget, míg az

A adathalmaz elsősorban kiegészítő szerepet tölt be.

A Venn-diagram az `merge/generated/venn/venn_diagram.png` állományba került mentésre, az elemszámokat tartalmazó összefoglaló táblázat pedig `venn_table.csv` formátumban is elérhető.

4.1.2. Forrásösszegzés (Source Summary)

A *merged master* táblában minden rekordhoz tartozik egy *sources* mező, amely jelzi, hogy az adott sor mely eredeti adatforrás(ok)ból származik (A [16], B [17] és C [18]). Ez lehet egyetlen forrás (például A), vagy több forrás kombinációja (például B, C vagy A,B,C).

A forrásonkénti rekordösszesítő célja annak feltérképezése volt, hogy a végső D adathalmaz milyen arányban épül az egyes forrásokra, illetve milyen mértékű átfedés figyelhető meg közöttük. Az elemzés során meghatározásra kerül:

- hány rekord származik kizárólag az A, B vagy C forrásból,
- hány rekord érkezik két forrás kombinációjából,
- valamint hány rekord található meg mindhárom adatforrásban.

Az összesítés eredménye egy CSV formátumú táblázatban kerül mentésre, amely a `merge/generated/reports/source_summary.csv` fájlban érhető el. Ez a táblázat jól áttekinthető módon mutatja meg az egyes forráskombinációkhoz tartozó rekordok számát, valamint azt is, hogy az adott kombináció tartalmazza-e az A, B vagy C forrást.

A forrásonkénti rekordösszesítés kulcsszerepet játszik annak megértésében, hogy az adathalmazok mennyire fedik egymást, és hogy az összevonás során a meghatározott prioritási sorrend ($C \rightarrow B \rightarrow A$) hogyan jelenik meg a végső adatmodellben.

Az alábbi 4.1 függvény mutatja be a forrásonkénti rekordösszesítő előállításának megvalósítását:

```
def save_source_summary(d: pd.DataFrame, output_dir: str):

    summary = d["sources"].value_counts().reset_index()
    summary.columns = ["source_combination", "record_count"]

    summary["contain_A"] = summary["source_combination"]
    .str.contains("A")
    summary["contain_B"] = summary["source_combination"]
    .str.contains("B")
    summary["contain_C"] = summary["source_combination"]
    .str.contains("C")

    output_file = os.path.join(output_dir, "source_summary.csv")
    summary.to_csv(output_file, index=False, encoding="utf-8-sig")
```

```
logging.info(f"Source summary saved: {output_file}")
```

4.1. Kódpélda. Forrásonkénti rekordösszesítő előállításának megvalósítása

4.1.3. Integritásvizsgálat

Az integritásvizsgálat célja a merged tábla alapvető adatminőségi problémáinak feltárása, amelyek az összevonási folyamat során vagy a forrásadatok sajátosságai miatt jelenhetnek meg. Az ellenőrzések elsősorban a kulcsazonosítók, a kötelező mezők és a dátumformátumok konzisztenciájára fókuszálnak, mivel ezek hibái közvetlenül befolyásolják a későbbi normalizálási lépések és az SQL importálás biztonságát.

A vizsgálat az alábbi ellenőrzéseket hajtja végre:

- duplikált *appid* értékek azonosítása,
- hiányzó *appid* értékek számlálása,
- hiányzó játéknevek (*name*) ellenőrzése,
- hiányzó vagy üres forrásjelölés (*sources*) vizsgálata,
- érvénytelen *release_date* értékek detektálása dátumkonverzióval.

Az ellenőrzés eredménye egy külön CSV jelentésben kerül mentésre `merge/generated/reports/integrity_report.csv` néven, amely a hibák számát ellenőrzésenként összesítve tartalmazza. Ez a jelentés az összefésülés-folyamat utólagos ellenőrzésére és dokumentálására is alkalmas.

Az alábbi 4.2 függvény szemlélteti az integritásvizsgálat megvalósítását:

```
def validate_integrity(d: pd.DataFrame, output_dir: str):

    results = []

    results.append({
        "check": "Duplicate appids",
        "error_count": d["appid"].duplicated().sum()
    })

    results.append({
        "check": "Missing appids",
        "error_count": d["appid"].isna().sum()
    })

    if "name" in d.columns:
        results.append({
            "check": "Missing names",
```

```
        "error_count": d["name"].isna().sum()
    })

    if "sources" in d.columns:
        results.append({
            "check": "Missing sources",
            "error_count": (d["sources"] == "").sum()
        })

    if "release_date" in d.columns:
        invalid = pd.to_datetime(d["release_date"],
            errors="coerce").isna().sum()
        results.append({
            "check": "Invalid release_date",
            "error_count": invalid
        })

    integrity_df = pd.DataFrame(results)

    output_file = os.path.join(output_dir, "integrity_report.csv")
    integrity_df.to_csv(output_file, index=False, encoding="utf-8-sig")

    logging.info(f"Integrity check completed, saved to {output_file}")
```


4.2. Kódpélda. Integritásvizsgálat megvalósítása

4.2. Grafikonok

A fejezet következő része a legfontosabb leíró statisztikai eredményeket vizuális formában mutatja be. A grafikonok célja, hogy szemléletesen kiemeljék a megjelenések időbeli alakulását, a források szerinti különbségeket, valamint a műfaji és szezonális mintázatokat. Az ábrák minden esetben a *merged* adathalmazból származó, egységesített adatok alapján készültek. A diagramok a `notebooks/merge/generated/plots` könyvtárban érthetők el.

4.2.1. Hisztogramok és trendvizualizációk


Játékmegjelenések 2010 előtt



4.2. ábra. A Steam platformon megjelent játékok száma évente 2010 előtt

Ahogy azt a 4.2 ábrán is láthatjuk a 2010 előtti időszakban a megjelenésszámok viszonylag alacsonyak voltak, és jellemzően a hagyományos kiadói modell dominált. Ebben az érásban a belépési küszöb magasabb volt, az önálló fejlesztők és kisebb stúdiók megjelenése még korlátozott szerepet játszott a platform kínálatában.


Játékmegjelenések 2010 után



4.3. ábra. A Steam platformon megjelent játékok száma évente 2010 után

A 2010 utáni időszakban a megjelenésszámok jelentős növekedése figyelhető meg a 4.3 ábrán, különösen 2014-et követően. A 2020 és 2024 közötti években a megjelenések száma stabilan 10–20 ezer közötti tartományban mozgott évente, ami jól tükrözi a digitális disztribúció térnyerését és a platform nyitottabbá válását a kisebb fejlesztők számára.

Összes játék megjelenése évente



4.4. ábra. A Steam [1] platformon megjelent játékok száma évente (1997–2025 májusáig)

Az 4.4 ábra jól szemlélteti a videójáték-megjelenések számának hosszú távú növekedését. A 2014 utáni időszakban különösen meredek emelkedés figyelhető meg, amely szoros összefüggésbe hozható a Steam Direct [21] modell bevezetésével és az indie fejlesztők számának ugrásszerű növekedésével. A megjelenések száma 2024-ben érte el csúcspontját, több mint 21 000 új címmel. A 2025-ös érték részleges adatokat tartalmaz, mivel az adathalmaz csak az adott évig rendelkezésre álló megjelenéseket tartalmazza.


4.2.2. Forrás szerinti bontás (A, B, C kategória)

Az összefésült adathalmaz lehetőséget ad arra, hogy a játékmegjelenéseket az eredeti adatforrások szerint elkülönítve is vizsgáljuk. Ennek megfelelően az elemzés három kategóriát különböztet meg:

- **A adathalmaz [16]** – Steam [1] metaadatok korábbi, strukturált CSV-alapú forrása
- **B adathalmaz [17]** – SteamSpy [15] adatok (JSON-alapú, külső statisztikai forrás)


- **C adathalmaz [18]** – 2024–2025-ös, legfrissebb Steam adatgyűjtések

Az alábbi ábrák az egyes forrásokhoz tartozó játékmegjelenések számát mutatják évenkénti bontásban.




4.5. ábra. Az A kategóriába tartozó játékmegjelenések évenkénti alakulása

A kategória Az **A** forrás esetében jól látható a 4.5 ábrán, hogy a megjelenések száma korlátozottabb, és elsősorban a korábbi évek játékait feddi le. A 2015–2018 közötti időszakban átmeneti növekedés figyelhető meg, amelyet azonban a forrás időbeli lefedettségének kifutása követ. A 2018 utáni visszaesés nem piaci trendet, hanem az adatforrás strukturális lezárulását tükrözi.



4.6. ábra. A B kategóriába tartozó játékmegjelenések évenkénti alakulása

B kategória A **B** forrás növekedése jóval dinamikusabb, ahogy azt a 4.6 ábrán is láthatjuk. A 2019 utáni időszakban különösen jelentős emelkedés figyelhető meg, ami a SteamSpy [15] adatgyűjtési lefedettségének bővülésével magyarázható. 2025-ben már májusig több mint 2300 **B** kategóriás megjelenés történt, azonban ez az érték részleges adatot reprezentál, mivel az év még nem zárult le.




4.7. ábra. A C kategóriába tartozó játékmegjelenések évenkénti alakulása

C kategória A **C** kategória tartalmazza a legfrissebb adatokat, ezért itt figyelhető meg a legerőteljesebb növekedés. A 2021 utáni időszakban a megjelenések száma mere-

deken emelkedik, ami jól tükrözi a Steam platformon tapasztalható tartalombővülést és az indie fejlesztések dominanciáját. A 2025-ös érték ebben az esetben is részleges, mivel az adathalmaz csak az év első hónapjait tartalmazza. A C forrás modern időszaki felfutását a 4.7 ábra mutatja be.

4.2.3. Top 5 műfaj időbeli trendje

A 4.8 ábra a Steam [1] platformon megjelent videójátékok közül az öt leggyakoribb műfaj évenkénti megjelenésszámát mutatja be az adatbázis teljes időtartamára (1997–2025 májusáig).



4.8. ábra. A Top 5 műfaj időbeli trendje

A legnépszerűbb műfajok a vizsgált időszakban az alábbiak voltak: *Indie*, *Casual*, *Action*, *Adventure*, *Simulation*.

Az **Indie** műfaj toronymagasan vezet, és a modern időszakban (2014 után) jó közelítéssel a teljes PC-s játékkínálat bővülésének indikátoraként értelmezhető. Az indie címek számának növekedése szoros összefüggést mutat a Steam Direct [21] modell bevezetésével, amely jelentősen csökkentette a belépési küszöböt a fejlesztők számára.

A műfajok idősorai között rendkívül erős együttmozgás figyelhető meg. A 2014–2024 közötti időszakban számított korrelációs együtthatók minden műfajpár esetén kiemelkedően magas értékeket mutatnak. Ez arra utal, hogy a különböző műfajok növekedése nem egymás rovására történik, hanem egy közös, mögöttes piaci expanziót követ.

Hosszabb távon a volumenek aránya stabilnak tekinthető: a *Casual*, *Action* és *Adventure* műfajok megjelenésszáma nagyságrendileg az *Indie* megjelenések 50–70%-a között alakul, míg a *Simulation* műfaj részesedése ennek körülbelül a fele. Ennek meg-

felelően a műfajok idősorai nem tekinthetők függetlennek, és a teljes kínálat növekedése jól közelíthető egy központi volumenindikátor (Indie) és közel konstans műfajarányok segítségével.

Műfajok közötti korrelációk (2014–2024) A Top 5 műfaj idősorai közötti együttmozgást kvantitatív módon is ellenőriztem. Az alábbi táblázatok a Pearson-féle lineáris korrelációt [22], illetve a Spearman-féle rangkorrelációt [23] mutatják a 2014–2024 közötti időszakra számítva. A korrelációs eredményeket a 4.1 és 4.2 táblázatok foglalják össze.

	Action	Adventure	Casual	Indie	Simulation
Action	1.000	0.997	0.998	0.997	0.994
Adventure	0.997	1.000	0.998	0.994	0.996
Casual	0.998	0.998	1.000	0.997	0.996
Indie	0.997	0.994	0.997	1.000	0.992
Simulation	0.994	0.996	0.996	0.992	1.000

4.1. táblázat. Pearson-korreláció a Top 5 műfaj idősorai között (2014–2024)


	Action	Adventure	Casual	Indie	Simulation
Action	1.000	0.991	1.000	1.000	1.000
Adventure	0.991	1.000	0.991	0.991	0.991
Casual	1.000	0.991	1.000	1.000	1.000
Indie	1.000	0.991	1.000	1.000	1.000
Simulation	1.000	0.991	1.000	1.000	1.000

4.2. táblázat. Spearman-korreláció a Top 5 műfaj idősorai között (2014–2024)

A kétféle korrelációs mérőszám egybehangzóan rendkívül erős együttmozgást jelez, ami alátámasztja, hogy a vizsgált műfajok idősorai nem tekinthetők egymástól függetlennek.

4.2.4. Éves növekedési faktor (logaritmikus skálán)

A 4.9 ábra az egyes évek közötti növekedési faktort mutatja be, vagyis azt, hogy az adott évben megjelent játékok száma hányszorosára változott az előző évhez képest. Az ábrázolás logaritmikus skálán történt, amely lehetővé teszi a szélsőséges növekedési és visszaesési periódusok egyidejű áttekintését.



4.9. ábra. Éves növekedési faktor logaritmikus skálán


A logaritmikus skála jól kiemeli a kiugró éveket, különösen **2005** és **2014** környékén, amelyek a Steam [1] platform strukturális változásaihoz köthetők. A 2014-es ugrás egyértelműen összefügg a Steam Direct [21] modell bevezetésével, amely jelentősen megnövelte az új megjelenések számát.

A növekedési faktor az egységérték (1) körüli tartományban stagnáló piacot jelez, míg az ez alatti értékek visszaesést, az efeletti értékek pedig expanziót mutatnak. A **2015** utáni időszakban a növekedési faktor stabilizálódása figyelhető meg, ami arra utal, hogy a platform elérte a folyamatos, de kevésbé robbanásszerű bővülés szakaszát.

A **2025-ös érték** részleges adatokat tartalmaz, mivel az adathalmaz csak az év első hónapjainak (májusig bezárólag) megjelenéseit foglalja magában, ezért az adott év növekedési faktora nem tekinthető teljes értékűnek.

4.2.5. Év $\times$ nap hőtérkép

A 4.10 hőtérkép az egyes évek és naptári napok mentén mutatja a videójáték megjelenések intenzitását. A színezés a napi publikálások számát reprezentálja, így egyszerre szemlélteti a hosszú távú növekedési trendet és az esetleges szezonális mintázatokat.

4.10. ábra. Év $\times$ nap hőtérkép a játékmegjelenések intenzitásáról


A hőtérkép látványosan mutatja a publikálási intenzitás hosszú távú növekedését és a szezonális jelenlétét. A 2014 utáni időszakban a megjelenések sűrűsége folyamatosan emelkedik, míg a 2023–2025 közötti években már szinte minden napra több tucat új játék jut.

A mintázat alapján a publikálás nem egyenletes: bizonyos időszakokban és napokon koncentráltabb aktivitás figyelhető meg. Mivel azonban az év napjainak hétköznapra esése évről évre eltér, a hét napjaihoz köthető hatások ebben az ábrázolásban részben elmosódnak.

4.2.6. Év $\times$ (ISO hét $\times$ hét napja) hőtérkép

A 4.11 ábra a videójáték-megjelenések időbeli eloszlását szemlélteti egy olyan átrendezett időtengely mentén, amely az egyes naptári napokat az ISO szabvány szerinti hét száma és a hét napja alapján rendezzi sorba.

Az ábra függőleges tengelye az éveket jelöli, míg a vízszintes tengely az adott év összes napját tartalmazza úgy, hogy azok először az ISO-hetek (1–53), azon belül pedig a hét napjai szerint követik egymást. Ennek eredményeként a vízszintes tengelyen egymás mellett jelennek meg azon napok, amelyek az év különböző időpontjaiban a hétnak ugyanarra a napjaira estek.



4.11. ábra. $\text{Év} \times (\text{ISO hét} \times \text{hét napja})$ hő térkép a játékmegjelenések intenzitásáról

A hő térkép egy-egy cellája az adott évben, az adott ISO hét adott napján megjelent játékok számát mutatja, ahol a színezés intenzitása a publikálások számával arányos. A világosabb színek alacsonyabb, a sötétebb színek magasabb megjelenésszámot jeleznek.


Az ilyen típusú igazítás előnye, hogy csökkenti a naptári eltolódások hatását (például azt, hogy ugyanaz a dátum különböző években a hét más napjaira esik), és lehetővé teszi a hét napjaihoz kötődő ciklikus mintázatok azonosítását. A 2014 utáni időszakban jól látható, hogy a megjelenések intenzitása nemcsak éves szinten növekszik, hanem a hét napjai szerint is következetes szerkezetet mutat.

A modern években a magas intenzitású sávok szinte az év teljes hosszán megjelennek, ami arra utal, hogy a publikálás nem kampányszerű, hanem folyamatos jellegű, és stabil, strukturális piaci bővülést tükröz.

4.3. Szezonális mintázatok – havi, heti és napi bontás

A játékmegjelenések időbeli szerkezetét több időskálán vizsgáltam, mivel az eltérő aggregálási szintek különböző jellegű mintázatokat emelnek ki. A havi, heti és napi bontás együttesen lehetővé teszi a hosszú távú trendek és a rövidebb periódusú ciklikusság elkülönítését.


4.3.1. Havi szezonális mintázatok



4.12. ábra. Játékmegjelenések havi bontásban – évek egymásra rajzolva

A havi bontás jól szemlélteti (4.12 ábra) a hosszabb távú szezonalitást és az évről évre fokozódó volumen növekedést. A modern időszakban (2014 után) a megjelenések száma gyakorlatilag minden hónapban emelkedő trendet követ, jelentősebb, tartós visszaesések nélkül. Ez arra utal, hogy a piac bővülése nem egy-egy kiemelt időszakhoz, hanem az év egészéhez köthető.


4.3.2. Heti szezonális mintázatok



4.13. ábra. Játékmegjelenések heti bontásban – évek egymásra rajzolva

A heti bontás (4.13 ábra) kisimítja a napi szintű ingadozásokat, miközben az éven belül jelentkező periodikus mintázatok továbbra is jól azonosíthatók maradnak. Az egyes évek görbéi jelentős együttmozgást mutatnak, ami arra utal, hogy a publikálási dinamika időben stabil szerkezetet követ. A csúcs- és alacsonyabb aktivitású időszakok évről-évre hasonló hetekhez köthetők.

4.3.3. Napi mintázatok ISO-heti igazítással




4.14. ábra. Heti bontás ISO-heti igazítással – a weekday-hatás csökkentése

A napi szintű adatok önmagukban rendkívül zajosak, elsősorban a hét napjának hatása miatt. Ezért a napi megjelenéseket ISO-heti bontásban aggregáltam, amellyel a weekday-hatás jelentős része kiküszöbölhető.

Az így kapott idősorok (4.14 ábra) már jól összevethetők egymással: a csúcsok és visszaesések időben nagyrészt egybeesnek, ami erős együttmozgásra és ismétlődő publikálási mintázatokra utal. A 2020 utáni időszakban szinte minden héten tartósan magas megjelenésszám figyelhető meg.

4.4. 2026-os előrejelzés logaritmikus skálán illesztett lineáris trend alapján

A trendillesztés során az éves játék megjelenések számát természetes alapú logaritmikus transzformációnak vettem alá, majd az így kapott adatokra lineáris regressziós modellt illesztettem legkisebb négyzetek módszerével. Az illesztés Python környezetben, a `scikit-learn` könyvtár `LinearRegression` osztályának felhasználásával történt, alapértelmezett beállítások mellett.



4.15. ábra. Játékmegjelenések előrejelzése 2026-ra log-lineáris trend alapján

A 2026-os becslést a 4.15 ábra mutatja be. A modern évek (2014–2024) adatai-ra illesztett log-lineáris (exponenciális) trend alapján a 2026-os évre **megközelítőleg 35 789 új játékmegjelenés** becsülhető.

A modell becslési pontosságát visszatesztelés során az abszolút százalékos hiba (APE, Absolute Percentage Error) [24] segítségével értékeltem, amely az alábbi módon számítható:

$$\text{APE} = \frac{|\hat{y} - y|}{y} \cdot 100\%, \quad (4.1)$$

ahol y a tényleges megfigyelt érték, $\hat{y}$ pedig a modell által becsült érték.

A modell 2024-re visszatesztelve körülbelül **10%-os túlbecslést** mutatott, ezért a 2026-os érték *optimista forgatókönyvként* értelmezendő, és inkább felső becslésnek tekinthető. A növekedés üteme a piac telítődése vagy platformszabályozási hatások miatt a következő években mérséklődhet.


4.4.1. Az előrejelzés pontosságának vizsgálata

A 2026-os évre készített becslés megbízhatóságát expanding-window [25] típusú, egy-lépéses visszateszteléssel vizsgáltam. A módszer lényege, hogy a modell minden lépésben kizárólag az adott évnél korábbi adatokra illesztett logaritmusos trend alapján becsüli a következő évet, majd az előrejelzést összeveti a ténylegesen megfigyelt értékkel.

A vizsgálat során a tréninghalmaz kezdőéve rögzített (2014), majd a trendillesztéshez felhasznált megfigyelési pontok száma évről-évre bővül, ahol egy tréningpont

egy adott év összesített játékmegjelenésszámát jelenti. A becslési hiba alakulását az abszolút százalékos hiba (APE) segítségével értékeltem.


Az eredményeket a 4.16 ábra szemlélteti.



4.16. ábra. Expanding-window visszatesztelés – a becslési hiba alakulása a trendillesztéshez felhasznált tréningévek számának függvényében

Az ábra alapján megfigyelhető, hogy kevés tréningadat esetén a becslések jelentős hibával terheltek, ami a növekedési trend instabil becslésére vezethető vissza. Ahogy azonban a tréningévek száma növekszik, a becslési hiba fokozatosan csökken, majd stabilizálódik. A 10 éves tréningablaknál a relatív hiba már megközelítőleg 10%, ami a modell konzisztens viselkedését jelzi.

Az abszolút hiba alakulását a becslült és a tényleges értékek különbségeként a 4.17 ábra mutatja be.




4.17. ábra. Expanding-window visszatesztelés – előrejelzési hiba alakulása

Az ábra alapján megfigyelhető, hogy a vizsgált időszakban a becslési hiba jellemzően

pozitív, ami arra utal, hogy a modell többnyire felülbecsüli a tényleges játékmegjelenésszámot. A hiba nagysága ugyanakkor a tréningidőszak bővülésével mérséklődik.

A becst és a tényleges értékek időbeli egyttalakulását a 4.18 ábra szemlélteti.




4.18. ábra. Expanding-window visszatesztelés – becst és tényleges értékek összehasonlítása

Az ábra alapján látható, hogy a becslések jól követik a játékmegjelenések növekvő trendjét, azonban a becst értékek több évben a tényleges adatok felett helyezkednek el, ami a modell optimista jellegére utal.

A teljes vizsgált időszakban a modell jellemzően felülbecsülte a tényleges megjelenésszámot. Ez arra utal, hogy a játékmegjelenések növekedése nem tisztán exponenciális jellegű, és a piac bővülését strukturális tényezők (például telítődési hatások) mérséklék.

4.5. Modellvalidáció – 2024 visszateszt



4.19. ábra. 2024-es előrejelzés tesztje a log-lineáris modell alapján a korábbi adatokra

A 2024-es évre vonatkozó teszt eredményei a 4.19 ábrán láthatók. A modell teljesítményének ellenőrzésére a 2014–2023 közötti adatokon tanított log-lineáris (legkisebb négyzetek módszerével illesztett) trend segítségével előrejeleztem a 2024-es évet. A becslés **23 717** megjelenést adott, míg a tényleges érték **21 454** volt, ami hozzávetőleg **10%-os eltérést** jelent.

Ez az eredmény arra utal, hogy a modell a közelmúltban enyhén optimista, ugyanakkor a növekedési trend irányát és nagyságrendjét helyesen ragadja meg, így hosszabb távú extrapolációs alapként óvatosan alkalmazható.

5. fejezet

Osztályozási problémák

Ebben a fejezetben a korábban előkészített és egységesített Steam [1] adatokból két, egymástól eltérő *bináris osztályozási* feladatot fogalmazok meg és vizsgálok. A két feladat közös jellemzője, hogy mindkettőnél a célváltozó két értéket vehet fel, és a modellezés célja a játékok egyes tulajdonságai alapján a megfelelő osztály előrejelzése. A módszertan mindkét esetben egységes: adatkijelölés $\rightarrow$ előfeldolgozás $\rightarrow$ tanító/teszt halmaz képzés $\rightarrow$ modellillesztés $\rightarrow$ teljesítménymérés.

A két vizsgált osztályozási probléma:

- **Videójáték „sikerességének” becslése** (pozitív értékelési arány alapján képzett címke),
- **Multiplayer vs. singleplayer** kategória becslése (címkék és leírás alapján képzett címke).

A két osztályozási feladat munkafüzete a `notebooks/Classification` jegyzékben található meg. A fejezet célja nem egyetlen konkrét algoritmus kiemelése, hanem egy átlátható, reprodukálható osztályozási munkafolyamat bemutatása, amely később új célváltozókra is kiterjeszthető.

5.1. Kutatási módszertan és feldolgozási lépések

Mindkét osztályozási feladatnál az alábbi feldolgozási folyamatot alkalmaztam:

1. **Cél (target) megfogalmazása:** a bináris osztálycímke definíciója (pl. sikeres/nem sikeres, multiplayer/nem multiplayer).
2. **Adatok kijelölése:** azoknak a rekordoknak és attribútumoknak a kiválasztása, amelyek relevánsak a célváltozóhoz.

3. **Előfeldolgozás és jellemzőképzés:** hiányzó értékek kezelése, numerikus változók skálázása, kategóriák binarizálása, illetve a szöveges mezők vektorizálása (TF-IDF [26]).
4. **Tanítás és tesztelés:** a tanító és teszt halmazok szétválasztása, majd modellillesztés.
5. **Értékelés:** több metrika alapján (pontosság, precízió, recall, F1 [27]; ahol releváns, ROC-AUC [28]), továbbá konfúziós mátrix [27] és részletes osztályozási jelentés alapján.

A módszertan előnye, hogy a két külön feladatra ugyanaz a *logikai szerkezet* alkalmazható, miközben a célváltozó és a felhasznált jellemzők a feladat sajátosságaihoz igazodnak.

Alkalmazott teljesítménymérő metrikák

Az osztályozási modellek teljesítményének értékelésére több különböző metrikát alkalmaztam, amelyek a predikciók különböző aspektusait ragadják meg.

Az alapvető mutatók közé tartozik a pontosság (Accuracy), a precízió (Precision), a visszahívás (Recall) és az F1-mérték [27]. Ezek a metrikák a konfúziós mátrix elemein alapulnak, és információt adnak a modell tévesztéseinek jellegéről.

A modellek rangsorolási képességének értékelésére a ROC-AUC (Receiver Operating Characteristic – Area Under Curve) [28] mutatót is alkalmaztam. A ROC görbe a valódi pozitív arány (true positive rate) és a hamis pozitív arány (false positive rate) kapcsolatát ábrázolja különböző döntési küszöbértékek mellett.

A ROC-AUC érték a görbe alatti területet méri, amely 0 és 1 közötti értéket vehet fel. Az 1 érték tökéletes osztályozást, a 0.5 érték pedig véletlenszerű besorolást jelent. Ez a metrika küszöbfüggetlen módon értékeli a modell teljesítményét, ezért különösen alkalmas kiegyensúlyozatlan osztályeloszlás esetén is.

A ROC-AUC mutató értelmezhető annak valószínűségékként, hogy a modell egy véletlenszerűen kiválasztott pozitív példát magasabb valószínűséggel sorol a pozitív osztályba, mint egy véletlenszerűen kiválasztott negatív példát. Ez különösen hasznos a videójátékok sikerességének becslése során, ahol a cél nemcsak a bináris döntés, hanem a játékok relatív rangsorolása is.

5.2. Vizsgálat 1: Videójáték sikerességének becslése

5.2.1. A probléma specifikációja (cél)

A feladat célja annak előrejelzése, hogy egy játék *sikeressnek* tekinthető-e. A címke a felhasználói értékelésekből származtatott: a pozitív értékelések arányát (*positive ratio*) számítom, és küszöböléssel képezem a bináris osztályt. Azoknál a rekordoknál, ahol nincs elegendő/értelmezhető értékelés (pl. 0 összes értékelés), a címke nem értelmezhető, ezért ezek a rekordok a tanításhoz nem kerülnek felhasználásra.

5.2.2. Adatkijelölés és jellemzők


A sikeresség-becsléshez olyan változókat választottam, amelyek a piaci teljesítménnyel és a játék jellemzőivel kapcsolatban állhatnak. A munkafüzetben az alábbi típusú jellemzők jelennek meg:

- **Numerikus alapjellemzők:** például ár (*price*), korhatár (*required_age*), megjelenési év (*release_date*), és további, adathalmazban elérhető számszerű mutatók.
- **Kategória jellegű változók:** műfajok és kategóriák bináris indikátorváltozókká alakítva (multi-hot [35] reprezentáció), hogy a többértékű mezők is használhatók legyenek klasszikus modellekben.


A jellemzők kiválasztását megelőzően a numerikus változók közötti kapcsolatok feltárására korrelációvizsgálatot végeztem annak ellenőrzésére, hogy az egyes attribútumok nem hordoznak-e jelentős mértékben redundáns információt. A vizsgálat eredményei alapján a numerikus változók között nem volt megfigyelhető erős lineáris kapcsolat, ezért egyik változó kizárása sem volt indokolt.

A dimenziócsökkentési módszerek (például főkomponens-analízis) alkalmazhatóságát szintén megvizsgáltam. Az eredmények azt mutatták, hogy az információ nem koncentrálódik néhány komponensbe, így a dimenziócsökkentés nem eredményezett volna lényegesen egyszerűbb reprezentációt az értelmezhetőség romlása nélkül. Ennek megfelelően a további elemzések során az eredeti jellemzők kerültek felhasználásra.

A korrelációvizsgálat eredményeit a 5.1 ábra, a PCA kumulált magyarázott varianciáját pedig a 5.2 ábra szemlélteti (a függelékben).



5.1. ábra. Numerikus változók korrelációs mátrixa



5.2. ábra. A numerikus változók PCA-alapú kumulált magyarázott varianciája

5.2.3. Előfeldolgozás

A kiválasztott jellemzők modellbarát formára alakításához egységes előfeldolgozási lépéseket alkalmaztam. A numerikus változókat skálázom, a kategória jellegű attribútumokat pedig bináris indikátorváltozókká alakítom. Ennek célja, hogy a különböző típusú jellemzők egyetlen, egységes bemeneti mátrixban jelenjenek meg, amely közvetlenül felhasználható a tanuló algoritmusok számára.

5.2.4. Tanítás/tesztelés és metrikák

Az adathalmazt tanító és teszt halmazra bontottam 80–20% arányban. A felosztás során ügyeltem arra, hogy a sikeres és nem sikeres játékok aránya mindkét részhalmazban megegyezzen az eredeti adathalmaz eloszlásával. Ez biztosítja, hogy a modell tanítása és értékelése során egyik osztály se legyen felül- vagy alulreprezentált.


A teljesítményt több metrika alapján értékeltem:

- **Accuracy** (pontosság) [27] – összes helyes besorolás aránya,
- **Precision** (precízió), **Recall**, **F1** [27] – különösen hasznos, ha az osztályok eloszlása nem tökéletesen egyenletes,
- ahol releváns, **ROC–AUC** [28] – rangsorolási minőség mérésére.

5.2.5. Mennyiségi jellemzők és javasolt ábrák

Az adathalmaz több olyan mennyiségi jellemzőt tartalmaz, amelyek számszerű formában írják le a videójátékok tulajdonságait és a felhasználói visszajelzéseket. Ezek közé tartozik többek között a játék ára, megjelenési éve, korhatár-besorolása, valamint a felhasználói értékelésekhez kapcsolódó mennyiségek.

A sikeresség mérésére használt pozitív értékelési arány folytonos változó, amelynek eloszlása önmagában is fontos információt hordoz. Az eloszlás vizsgálata rámutat arra, hogy a játékok többsége magas pozitív visszajelzési aránnyal rendelkezik, ugyanakkor kisebb részük alacsony értékelési arányt mutat. Ez az eloszlás indokolja a később alkalmazott bináris osztályozási küszöbérték bevezetését. A pozitív értékelések arányának eloszlását a 5.3 ábra szemlélteti.



5.3. ábra. A pozitív értékelések arányának eloszlása a videójátékok között

Amennyiben a játékok megjelenési ideje is rendelkezésre áll, lehetőség nyílik a pozitív értékelések arányának időbeli vizsgálatára is. Az évek szerinti bontás alapján megfigyelhető, hogy a pozitív visszajelzések átlagos aránya nem állandó, hanem hosszabb távon változó tendenciát mutat. Ez arra utalhat, hogy a felhasználói értékelési szokások, illetve a platform jellege időben módosult. A pozitív értékelések átlagos arányának alakulását az évek függvényében a az 5.4 ábra mutatja be.



5.4. ábra. A pozitív értékelések átlagos arányának alakulása az évek függvényében

A bemutatott ábrák nemcsak leíró statisztikai szerepet töltenek be, hanem meg-
alapozzák a későbbi prediktív modellezést is, mivel rávilágítanak a sikerességi mutató

eloszlására és időbeli viselkedésére.

5.3. Vizsgálat 2: Multiplayer vs. singleplayer osztályozás

5.3.1. A probléma specifikációja (cél)


A második feladat célja annak meghatározása, hogy egy játék inkább *multiplayer* jellegű-e vagy *singleplayer* jellegű. A címkét a rendelkezésre álló kategória- és tag-ek alapján képeztem: a multiplayerhez kapcsolódó jelölések (pl. *Multi-player*, *Online Multi-Player*, *Co-op* stb.) jelenléte esetén a rekord a multiplayer osztályba kerül.

5.3.2. Adatkijelölés és jellemzők

Ehhez a feladathoz a játékok *szöveges leírásait* és a kapcsolódó metaadatokat használtam fel, mivel a multiplayer jelleg elsősorban a játékmechanikákra és funkciókra vonatkozó információkból vezethető le.

A numerikus jellemzők (például ár, értékelésszám, átlagos játékidő vagy Metacritic-pontszám) előzetes vizsgálata során korrelációanalízist és főkomponens-elemzést alkalmaztam. Ezek az elemzések azt mutatták, hogy a célváltozó (*multiplayer vs. singleplayer*) csak gyenge kapcsolatot mutat a mennyiségi attribútumokkal, valamint hogy a numerikus jellemzők erősen redundáns információt hordoznak. Ez alapján a numerikus változók nem tekinthetők elsődleges prediktoroknak a vizsgált osztályozási feladatban.


Ennek megfelelően a jellemzőképzés fókuszába a szöveges és strukturált leíró információk kerültek, amelyek közvetlenebb módon tükrözik a játékok funkcionalitását és játékmenetét.



5.5. ábra. A numerikus jellemzők és a célváltozó kapcsolata

A korrelációs mátrix alapján különösen magas kapcsolat figyelhető meg a *num_reviews_total*, *positive* és *negative* változók között. Ez a jelenség a változók definíciójából fakad: az összes értékelésszám közelítőleg a pozitív és negatív értékelések összege, így ezek nem független információforrások. A magas korreláció tehát strukturális eredetű, és a jellemzők redundáns jellegére utal.

A numerikus jellemzők és a célváltozó kapcsolatát a 5.5 ábra szemlélteti.



5.6. ábra. A főkomponens-elemzés eredményei

A főkomponens-elemzés eredményeit a 5.6 ábra mutatja.

A felhasznált jellemzők a következők voltak:

- **Szöveges mezők:** a játék részletes leírása (*about_the_game*) és rövid leírása (*short_description*),

- **Szöveges reprezentáció:** TF-IDF (Term Frequency – Inverse Document Frequency) [26] vektorizálás, amely a gyakori, de kevésbé informatív szavakat leértékeli, míg a megkülönböztető kifejezéseket nagyobb súllyal emeli ki,
- **Strukturált jellemzők:** a játékokhoz tartozó címkék (tagek) és műfajok, bináris (multi-hot) [35] kódolás formájában.

Ez a jellemzőválasztás lehetővé tette, hogy a modellek egyszerre használják ki a természetes nyelvű leírásokban rejlő szemantikai információt és a metaadatok explicit módon megadott kategorizálását.

5.3.3. Előfeldolgozás

A multiplayer vs. singleplayer osztályozási feladat során a játékok szöveges leírásait numerikus reprezentációvá kellett alakítani, hogy azok gépi tanulási modellek bemeneteként felhasználhatók legyenek. Ennek érdekében a szöveges mezőket TF-IDF vektorizálással dolgoztam fel.

A TF-IDF módszer célja, hogy az adott dokumentumban gyakran előforduló, de a teljes szövegállományban ritkább szavakat nagyobb súllyal reprezentálja, miközben a sok dokumentumban megjelenő, kevésbé informatív kifejezések hatását csökkenti. Ez különösen alkalmas olyan feladatokra, ahol a megkülönböztető szavak és kifejezések jelentős szerepet játszanak az osztályozásban.

A vektorizálás során unigram és bigram kifejezések kerültek figyelembevételre, valamint minimális dokumentumgyakorisági küszöb (*min_df*) és maximális szókészlet-méret (*max_features*) került beállításra a ritka, zajos kifejezések kiszűrése érdekében. Az előfeldolgozás részeként a hiányzó leírásokat és az üres szövegeket eltávolítottam, így biztosítva a konzisztens bemeneti adatkészletet.

A TF-IDF vektorizálás eredményeként egy $(104\,701 \times 50\,000)$ dimenziójú, ritka mátrix jött létre, ahol a sorok az egyes játékok leírásait, az oszlopok pedig a szókészlet elemeit (unigramok és bigramok) reprezentálják. A szókészlet mérete elérte az előre meghatározott *max_features* = 50 000 korlátot, ami a szövegállomány jelentős nyelvi változatosságára utal.

A nagy dimenziószám és a ritka reprezentáció indokoltá teszi lineáris osztályozó algoritmusok alkalmazását, mint a logisztikus regresszió [30] vagy a lineáris SVM [33], amelyek hatékonyan kezelik a magas dimenziós, szórványos jellemzőtereket.


5.3.4. Tanítás/tesztelés és metrikák

A tanító/teszt felosztást stratifikált módon végeztem, hogy az osztálycímkék eloszlása mindkét részhalmazban megőrződjön. A modell teljesítményét az osztályozási felada-

toknál szokásos metrikák segítségével értékeltem (Accuracy, Precision, Recall, F1 [27], valamint ahol releváns, ROC-AUC [28]), az előző alfejezetben bemutatott módon.

5.3.5. Mennyiségi jellemzők és osztályeloszlás

A multiplayer és singleplayer játékok arányát az 5.7 ábra szemlélteti. Az adathalmaz erősen kiegyensúlyozatlan, a singleplayer játékok jelentős többségben vannak, ami indokolja az osztályozási modellek értékelésénél a pontosság mellett további metrikák (például Precision, Recall és F1-mérték) alkalmazását.



5.7. ábra. A célváltozó eloszlása: Singleplayer vs Multiplayer


A szöveges leírás hosszának eloszlását osztályonként az 5.8 ábra szemlélteti. Az ábra normalizált gyakoriságokat mutat. A szélsőséges értékek vizuális torzító hatásának csökkentése érdekében az ábrázolás a 99. percentilisig korlátozott tartományra fókuszál: a jobb oldali legfelső 1%-ba eső leíráshosszakat nem távolítottam el az adathalmazból, hanem a hisztogramon a 99. percentilis értékére korlátoztam. Ezáltal a grafikon az esetek 99%-ának eloszlását mutatja, és jobban áttekinthetővé válik a fő tömeg szerkezete.

Megfigyelhető, hogy mindkét osztály esetén az eloszlás erősen jobbra ferde, a magas értékek irányába kifejezett elnyúlással jellemezhető, ami kizárja a normalitás feltételezését. Az eloszlás alakja lognormális jellegre utal, ami összhangban van a szöveghossz multiplikatív természetével.

A multiplayer játékok leírásai hosszabbak és nagyobb szórást mutatnak. A medián szószám multiplayer esetén 250 (IQR [29] 169–362), míg singleplayer esetén 201 (IQR: 137–291). Az átlagos leíráshossz szintén magasabb multiplayer játékoknál (29 004 szó), mint singleplayer esetén (23 476 szó). A felső 1%-ba tartozó értékek is jelentősen nagyobbak (multiplayer: 97 525 szó, singleplayer: 782 szó), ami erősebb felső tartomány-


beli elnyúlásra utal.

Az eloszlások közötti különbségek arra utalnak, hogy a leírás hossza diszkriminatív információt hordozhat az osztályok között, ami indokolja a szöveges jellemzők bevonását a későbbi modellezési lépések során.



5.8. ábra. A leírás hosszának eloszlása osztályonként (normalizált, 0–99. percentilis)

A $\log(1 + \text{szószám})$ transzformáció csökkenti a magas értékek irányába mutató elnyúlás mértékét, és az eloszlásokat közel szimmetrikussá teszi (lásd 5.9 ábra), ami tovább erősíti a lognormális jelleg feltételezését.



5.9. ábra. A leírás hosszának eloszlása $\log(1 + \text{szószám})$ transzformáció után

5.4. Összegzés és további vizsgálati lehetőségek

Az 5. fejezetben két, egymástól eltérő bináris osztályozási problémát fogalmaztam meg a Steam [1]-adathalmaz alapján. A célváltozók definiálását részletes jellemzőelemzés és eloszlásvizsgálat előzte meg, amelyek rávilágítottak az egyes feladatok eltérő jellegére és a releváns prediktorváltozók körére.

A sikeresség becslésére irányuló feladat esetében a numerikus és kategória jellegű változók együttes alkalmazása indokoltnak bizonyult, míg a multiplayer vs. singleplayer osztályozásnál a szöveges leírások és strukturált metaadatok hordozzák a legfontosabb megkülönböztető információt. A leíráshossz eloszlásának vizsgálata azt is megmutatta, hogy a szöveges jellemzők statisztikai tulajdonságai nemlineáris jellegűek, ami befolyásolja a később alkalmazott modellek megválasztását.

A bemutatott elemzések megalapozták a következő fejezetben tárgyalt osztályozási modellek kiválasztását és értékelését. További vizsgálati lehetőséget jelenthetne például összetettebb szöveges reprezentációk (beágyazások, neurális nyelvi modellek), valamint alternatív küszöbértékek és költségérzékeny osztályozási megközelítések elemzése.

6. fejezet

Osztályozási feladatok megoldása

Ebben a fejezetben a korábban definiált osztályozási problémák konkrét megoldásának bemutatása és értelmezése történik. A cél nem csupán a prediktív teljesítmény számszerű értékelése, hanem annak vizsgálata is, hogy az alkalmazott modellek milyen jellemzők alapján hozzák meg döntéseiket, és ezek a döntések mennyiben tekinthetők értelmezhetőnek.

A fejezet két, eltérő jellegű problématerületre (domainre) bontva mutatja be az osztályozási feladatokat. Az első domain a videójátékok sikerességének becslésére fókuszál felhasználói visszajelzések és strukturált metaadatok alapján, míg a második domain a játékok multiplayer és singleplayer jellegének automatikus felismerését vizsgálja szöveges leírások és kapcsolódó metaadatok felhasználásával.

Mindkét esetben lineáris osztályozási módszerek kerültek alkalmazásra, amelyek megfelelő egyensúlyt biztosítanak a teljesítmény, a számítási hatékonyság és a modell-értelmezhetőség között. A fejezetben bemutatott eredmények megalapozzák a későbbi összehasonlító elemzést, amely a különböző módszerek és jellemzők hatását vizsgálja.


6.1. Domain 1: Videójáték sikerességének elemzése

6.1.1. A sikeresség-becslés eredményeinek értelmezése

A videójátékok sikerességének becslésére bináris osztályozási feladat került megfogalmazásra, ahol a cél annak eldöntése volt, hogy egy adott játék a felhasználói értékelések alapján sikeresnek tekinthető-e. A modell teljesítményének értelmezéséhez nemcsak az összesített metrikák, hanem a konfúziós mátrix is fontos információt szolgáltat.

A logisztikus regresszió [30] modell eredményeit a 6.1 ábra szemlélteti. A konfúziós mátrix alapján megfigyelhető, hogy a modell a sikeres játékokat nagyobb arányban ismeri fel helyesen, mint a nem sikereseket. Ez összhangban van azzal, hogy az adat-

halmazban a sikeres játékok aránya enyhén domináns.



6.1. ábra. Konfúziós mátrix a videójátékok sikerességének becslésére (logisztikus regresszió)


A mátrixból látható, hogy a tévesztések jelentős része a hamis pozitív és hamis negatív besorolásokból adódik. A modell viselkedése alapján megállapítható, hogy inkább optimista becslést ad: gyakrabban sorol nem sikeres játékot a sikeres kategóriába, mint fordítva. Ez a tulajdonság bizonyos alkalmazási esetekben előnyös lehet, amennyiben a cél a potenciálisan sikeres címek minél nagyobb arányú azonosítása.

A modell teljesítményét jellemző ROC–AUC [28] érték azt mutatja, hogy a becslés nem csupán bináris döntésként értelmezhető, hanem a játékok sikeresség szerinti rangsorolására is alkalmas. Ez azt jelenti, hogy a modell általában magasabb siker-
valószínűséget rendel a valóban sikeres játékokhoz, mint a nem sikeresekhez, ami megerősíti a modell használhatóságát elemzési célokra.

6.1.2. A sikerességet befolyásoló jellemzők értelmezése

A prediktív teljesítmény értékelése mellett fontos szempont annak vizsgálata is, hogy a modell mely bemeneti változókat tekinti meghatározónak a videójátékok sikerességének becslése során. Ennek érdekében a logisztikus regresszió modell koefficienseit elemeztem, mivel ezek közvetlenül értelmezhető információt adnak a változók hatásának irányáról és relatív erősségéről.

A legnagyobb abszolút értékű koefficiensekkel rendelkező változókat a 6.2 ábra mutatja be. Pozitív koefficiens esetén az adott jellemző növeli a sikeres besorolás valószínűségét, míg negatív érték csökkentő hatásra utal.



6.2. ábra. A legfontosabb változók a logisztikus regresszió modell alapján

Az eredmények alapján megfigyelhető, hogy a sikerességhez elsősorban nem technikai vagy árazási tényezők járulnak hozzá, hanem a játék (illetve szoftver) jellegére és használati módjára utaló attribútumok. Pozitív hatást mutat többek között az egyjátékos mód jelenléte, valamint a közösségi és kényelmi funkciókhoz kapcsolódó jellemzők (például Family Sharing, Steam Cloud vagy Steam Workshop).

Ezzel szemben negatív irányú hatás figyelhető meg bizonyos üzleti modellek, például az ingyenes (Free to Play) játékok esetében, illetve egyes speciális szoftverkategóriákhoz kapcsolódó változóknál. Ez arra utalhat, hogy ezeknél a címeknél a felhasználói elégedettség és az értékelési szokások eltérő mintázatot követnek.

Az elemzés rávilágít arra, hogy a logisztikus regresszió nem pusztán feketedobozos előrejelzőként használható, hanem lehetőséget ad a modell döntéseinek kvalitatív értelmezésére is.


6.1.3. A jellemzők számának hatása a prediktív teljesítményre

A jellemzők fontossági sorrendje alapján megvizsgáltam, hogyan változik a modell teljesítménye a felhasznált jellemzők számának csökkentésével.

Az eredmények azt mutatják, hogy már kis számú jellemző esetén is viszonylag jó prediktív teljesítmény érhető el. Például az öt legfontosabb jellemző használatával a modell pontossága 62.8%, míg az összes jellemző felhasználásával 65.3%-ot ér el.

Ez arra utal, hogy a sikeresség előrejelzéséhez szükséges információ jelentős része néhány kulcsjellemzőben koncentrálódik, és a további jellemzők csak mérsékelt mértékben javítják a prediktív teljesítményt.

A jellemzők számának és a modell teljesítményének kapcsolatát a 6.3 ábra szemlélteti.



6.3. ábra. A jellemzők számának hatása a modell teljesítményére

6.2. Domain 2: Multiplayer vs. singleplayer osztályozás


A második vizsgált osztályozási probléma a videójátékok multiplayer és singleplayer kategóriákba sorolására irányult. A bináris osztályozási feladat célja annak meghatározása volt, hogy egy adott játék rendelkezik-e többjátékos funkcionalitással, a játékok szöveges leírásai és strukturált metaadatai alapján.

A feladat megoldására több különböző modellt is kipróbáltam, amelyek eltérő jellemzőkészletekre épültek. A szöveges leírások feldolgozásához TF-IDF [26] alapú vektorizálást alkalmaztam, amely a szavak relatív fontosságát számszerűsíti a dokumentumok között, és hatékony bemeneti reprezentációt biztosít lineáris osztályozási modellek számára. Alternatív megközelítésként lehetőség lett volna fejlettebb természetes nyelvfeldolgozó eszközök, például a spaCy [34] könyvtár alkalmazására is, amely támogatja a tokenizálást, lemmatizálást és egyéb nyelvi elemzési lépéseket. A jelen vizsgálatban azonban a TF-IDF reprezentáció önmagában is megfelelő teljesítményt biztosított a feladat megoldásához.

Az eredmények alapján a legjobb teljesítményt a TF-IDF alapú szöveges jellemzőket és a strukturált metaadatokat együttesen alkalmazó lineáris SVM (LinearSVC) [33] modell nyújtotta. Ez a megoldás nemcsak az összesített pontosság, hanem a kiegyen-

súlyozottabb osztályonkénti teljesítmény tekintetében is kedvezőbbnek bizonyult.

A modell eredményeit a 6.4 ábra konfúziós mátrixa szemlélteti.



6.4. ábra. Konfúziós mátrix a multiplayer vs. singleplayer osztályozási feladatra (Combined LinearSVC)

A konfúziós mátrix alapján megfigyelhető, hogy a modell mindkét osztályt magas pontossággal képes elkülöníteni, miközben a kisebb elemszámú multiplayer osztály esetében is megfelelő visszahívási arányt ér el. Ez különösen fontos az adathalmaz kiegyensúlyozatlansága miatt, mivel a singleplayer játékok jelentős többségben vannak. Az eredmények azt mutatják, hogy a strukturált jellemzőkkel kiegészített szöveges reprezentáció hatékonyan segíti a többjátékos mechanikák felismerését.

6.2.1. A multiplayer besorolást befolyásoló jellemzők értelmezése

A prediktív teljesítmény vizsgálata mellett kiemelt figyelmet fordítottam a modell döntéseinek értelmezhetőségére is. A lineáris SVM modell tanult súlyainak elemzése lehetőséget biztosított annak feltárására, hogy mely jellemzők járulnak hozzá legnagyobb mértékben a multiplayer, illetve a singleplayer besoroláshoz.

Az elemzés alapján megállapítható, hogy a multiplayer irányba elsősorban olyan szöveges kifejezések és strukturált tagek tolódnak el, amelyek explicit módon többjátékos mechanikákra utalnak. Ilyenek például a *multiplayer*, *online*, *co-op*, *pvp* vagy *split screen* kifejezések, amelyek mind a játékok leírásaiban, mind a metaadatokban következetesen megjelennek.

Ezzel szemben a singleplayer besorolást inkább narratív, tanulási vagy egyéni játékelményhez kötődő kifejezések támogatják, mint például a *single player*, *prologue*, *tutorial* vagy *novel*. Ez arra utal, hogy a modell döntései nem véletlenszerű korrelációkon, hanem a játékmechanikákhoz és felhasználói élményhez szorosan kapcsolódó szemantikai mintázatokon alapulnak.

Az eredmények összességében azt mutatják, hogy a szöveges leírások és a strukturált jellemzők kombinációja nemcsak a prediktív teljesítményt javítja, hanem a modell döntéseinek értelmezhetőségét is megőrzi, ami fontos szempont az elemzési és kutatási célú alkalmazások esetében.

7. fejezet

Módszerek és eredményeik összehasonlítása

Ebben a fejezetben az előző fejezetekben bemutatott osztályozási feladatokra alkalmazott különböző gépi tanulási módszerek teljesítményét hasonlítom össze. A cél annak vizsgálata, hogy az eltérő modellek és jellemzőkészletek milyen mértékben befolyásolják a prediktív teljesítményt, különös tekintettel az osztályok közötti kiegyensúlyozottságra és a kisebbségi osztály felismerésére.

7.1. Domain 1: Videójáték sikerességének elemzése

7.1.1. A Random Forest és Gradient Boosting modellek összehasonlítása

A nemlineáris modellek implementációja a `scikit-learn` [13] könyvtár keretrendszerében történt. Mindkét modell döntési fák együttes alkalmazásán alapul, azonban eltérő tanítási stratégiát alkalmaznak.

A Random Forest modell [31] több, egymástól független döntési fa bootstrap mintavételezéssel történő tanításán alapul, majd az egyes fák predikcióit aggregálja (többségi szavazás). A modell tanítása során az alábbi fő paramétereket alkalmaztam:

- döntési fák száma: `n_estimators = 200`,
- véletlen inicializáció: `random_state = 42`,
- párhuzamos feldolgozás engedélyezve: `n_jobs = -1`,
- a további paraméterek a `scikit-learn` alapértelmezett beállításai (például `criterion = gini`, `bootstrap = True`, `max_depth = None`).

A Gradient Boosting modell [32] ezzel szemben szekvenciális módon építi fel a döntési fákat, ahol minden új fa a korábbi modellek hibájának csökkentésére törekszik. A tanítás során az alábbi paraméterezést alkalmaztam:

- véletlen inicializáció: `random_state = 42`,
- a további paraméterek a `scikit-learn` alapértelmezett beállításai (például az iterációk száma, tanulási ráta és fa-struktúra paraméterei).

A modellek tanítása azonos tanító- és teszhalmaz felosztás mellett történt, biztosítva az összehasonlítás konzisztenciáját. Az alkalmazott paraméterek a szakirodalomban gyakran használt alapértelmezett konfigurációt követik, amely megfelelő kiindulópontot biztosít a különböző modellek összehasonlító vizsgálatához.

7.1.2. Az alkalmazott osztályozási modellek és értékelésük

A logisztikus regresszió [30] mellett több további, gyakran alkalmazott osztályozási módszert is megvizsgáltam a videójátékok sikerességének becslésére. Mivel a jellemző-mátrix és a célváltozó már rendelkezésre állt, az összehasonlítás egységes adatfelosztás mellett, alapértelmezett paraméterezéssel történt.

Az összehasonlítás során Random Forest [31] és Gradient Boosting [32] modellek kerültek kipróbálásra. A modellek teljesítményét a ROC–AUC [28] mutató alapján értékeltem, mivel ez a metrika küszöbfüggetlen módon méri a modellek rangsorolási képességét. Az eredményeket a 7.2 táblázat foglalja össze.

Modell	ROC–AUC
Logisztikus regresszió	0.717
Random Forest	0.744
Gradient Boosting	0.754

7.1. táblázat. Különböző osztályozási modellek összehasonlítása ROC–AUC alapján

Az eredmények alapján megfigyelhető, hogy a nemlineáris modellek (Random Forest és Gradient Boosting) magasabb ROC–AUC értéket értek el, ami arra utal, hogy a játékok sikeressége és a bemeneti jellemzők közötti kapcsolat részben nemlineáris jellegű. Ugyanakkor a logisztikus regresszió továbbra is stabil és jól értelmezhető baseline modellt biztosít, amely megfelelő kiindulópontot jelent a további modellek értékeléséhez.

7.2. Domain 2: Multiplayer vs. singleplayer osztályozás

7.2.1. Az alkalmazott modellek áttekintése

A multiplayer vs. singleplayer osztályozási feladatra több különböző megközelítést alkalmaztam. Kiindulásként kizárólag a játékok szöveges leírásaira épülő baseline modelleket használtam, majd ezek teljesítményét strukturált metaadatok (bejegyzett *tagek* és *műfajok*) bevonásával is megvizsgáltam.

Az összehasonlítás során az alábbi modellek kerültek alkalmazásra:

- TF-IDF [26] + logisztikus regresszió [30] (csak szöveges jellemzők),
- TF-IDF + lineáris SVM [33] (csak szöveges jellemzők),
- TF-IDF + logisztikus regresszió strukturált jellemzőkkel,
- TF-IDF + lineáris SVM strukturált jellemzőkkel.

A modellek egységes tanító–teszt felosztás mellett kerültek kiértékelésre, stratifikált mintavételezéssel, annak érdekében, hogy az osztályok torz eloszlása ne befolyásolja a teljesítménymérést.

7.2.2. Teljesítménybeli különbségek elemzése

Az egyes modellek teljesítményét több metrika mentén értékeltem, beleértve a pontosság, precízió, recall és F1-mérték [27] értékeket. Az összehasonlítás során különös figyelmet kapott a kisebbségi multiplayer osztály felismerési képessége, mivel az adathalmaz jelentősen kiegyensúlyozatlan.

Az eredmények alapján megállapítható, hogy a lineáris SVM [33] modellek következetesen jobb teljesítményt nyújtottak, különösen a recall és az F1-mérték tekintetében. Ez arra utal, hogy ezek a modellek hatékonyabban kezelik a nagy dimenziós, ritka TF-IDF [26] reprezentációkat, mint a logisztikus regresszió.

A kizárólag szöveges jellemzőkre épülő modellek már önmagukban is jó teljesítményt értek el, azonban a strukturált jellemzők bevonása minden esetben további javulást eredményezett.

A 7.2 táblázat egyértelműen mutatja, hogy a strukturált jellemzők bevonása minden vizsgált modell esetében javulást eredményezett, különösen a kisebbségi multiplayer osztály visszahívási arányát és F1-mértékét tekintve.

7.2. táblázat. A különböző modellek teljesítményének összehasonlítása a multiplayer vs. singleplayer osztályozási feladatra

Modell	Jellemzők	Accuracy	Recall (MP)	F1 (MP)
LogReg	TF-IDF (szöveg)	0.933	0.852	0.829
LinearSVC	TF-IDF (szöveg)	0.937	0.833	0.833
LogReg	Szöveg + tagek + műfajok	0.955	0.893	0.883
LinearSVC	Szöveg + tagek + műfajok	0.958	0.880	0.889

A legjobb összteljesítményt a TF-IDF szöveges reprezentációt és a strukturált metaadatokat együttesen alkalmazó lineáris SVM modell érte el, ami alátámasztja a korábbi fejezetekben levont következtetéseket.

7.2.3. A strukturált jellemzők hatása

A tagek és műfajok bináris (multi-hot) [35] reprezentációjának hozzáadása különösen a multiplayer osztály visszahívási arányát növelte. Ez azt jelzi, hogy a strukturált metaadatok explicit módon hordozzák a játékmechanikákra vonatkozó információkat, amelyek hatékonyan kiegészítik a természetes nyelvű leírásokból kinyerhető mintázatokat.

A kombinált modellek esetében csökkent a hamis negatív besorolások, vagyis a másodfajú hibák száma, ami a kisebbségi osztály szempontjából kiemelten fontos javulást jelent.

7.2.4. Összegző értékelés

Az összehasonlító elemzés alapján megállapítható, hogy a TF-IDF [26] alapú szöveges reprezentációt és a strukturált metaadatokat együttesen alkalmazó lineáris SVM [33] modell bizonyult a leghatékonyabb megoldásnak a multiplayer vs. singleplayer osztályozási feladatra.

Ez a modell nemcsak magas összesített pontosságot ért el, hanem kiegyensúlyozott teljesítményt mutatott mindkét osztály esetében, miközben a döntési mechanizmusa értelmezhető és szakmailag indokolható maradt. Ez különösen fontos szempont elemzési és kutatási célú alkalmazásokban, valamint a későbbi továbbfejlesztések szempontjából is.

8. fejezet

Összegzés

A dolgozat célja a Steam platformról származó videójáték-adatok elemzése és különböző osztályozási feladatok megfogalmazása volt gépi tanulási módszerek alkalmazásával. A kutatás során egy valós, heterogén szerkezetű adathalmaz került feldolgozásra, amely numerikus változókat, kategória jellegű metaadatokat és szöveges leírásokat is tartalmazott. A munka egyik fontos célkitűzése az volt, hogy bemutassa, miként használhatók fel ezek az eltérő típusú információk prediktív modellezési feladatokban.

A feldolgozás első lépéseként az adatok tisztítása és egységesítése történt meg. Ez magában foglalta a hiányzó értékek kezelését, a változók típusának egységesítését, valamint a modellek számára megfelelő jellemzők kialakítását. A kategória jellegű mezők bináris reprezentációvá alakítása, illetve a szöveges leírások TF-IDF alapú vektorizálása lehetővé tette, hogy az eltérő típusú adatok közös jellemzőtérben jelenjenek meg.

A dolgozat két eltérő osztályozási problémát vizsgált. Az első feladat a videójátékok sikerességének becslése volt a felhasználói értékelésekből származtatott címke alapján. Ebben az esetben a strukturált metaadatokat és numerikus változókat alkották a prediktív modellek bemenetét. Az elemzés rámutatott arra, hogy a játékok egyes funkcionális jellemzői és platformszolgáltatásai kapcsolatban állhatnak a felhasználói visszajelzések által tükrözött sikerességgel.

A második vizsgált feladat a multiplayer és singleplayer játékok automatikus elkülönítése volt. Ebben az esetben a szöveges leírások és a strukturált tagek bizonyultak a leginformatívabb jellemzőknek. A szöveges reprezentáció lehetővé tette, hogy a modellek a játékmechanikákra és funkciókra utaló kifejezések alapján különítsék el a két kategóriát.

A különböző osztályozási modellek összehasonlítása azt mutatta, hogy mind a lineáris, mind a nemlineáris módszerek képesek értelmezhető és stabil predikciókat adni. A lineáris modellek előnye elsősorban az értelmezhetőségben és a nagy dimenziós jellemzőterek hatékony kezelésében jelentkezett, míg az ensemble módszerek bizonyos

esetekben jobb prediktív teljesítményt mutattak. Az eredmények összességében azt jelzik, hogy a videójátékokhoz kapcsolódó metaadatok és szöveges információk alkalmasak gépi tanulási modellek bemeneteként történő felhasználásra.

A dolgozat egyik fontos tanulsága, hogy a strukturált és a szöveges jellemzők kombinációja jelentősen növelheti az osztályozási modellek információtartalmát. A videójátékok leírásai és metaadatai nemcsak marketingcélú információkat hordoznak, hanem a játékmechanikákra és felhasználói élményre vonatkozó implicit jelzéseket is tartalmaznak, amelyek a prediktív modellek számára is hasznosak lehetnek.

A bemutatott megközelítés több irányban is továbbfejleszthető. A jövőbeni kutatások egyik lehetséges iránya összetettebb természetesnyelv-feldolgozási módszerek alkalmazása lehet, például szóbeágyazások vagy neurális nyelvi modellek bevonásával. Ezek képesek lehetnek a szövegek mélyebb szemantikai szerkezetének megragadására, ami tovább javíthatja az osztályozási teljesítményt.

További fejlesztési lehetőséget jelenthet összetettebb gépi tanulási modellek alkalmazása is, például mély neurális hálózatok vagy fejlettebb ensemble módszerek használata. Emellett érdemes lehet a sikeresség fogalmának finomabb modellezése, például többosztályos vagy regressziós megközelítés formájában, ahol a célváltozó nem bináris, hanem folytonos vagy több kategóriából áll.

Összességében a dolgozat bemutatta, hogy a Steam platformon elérhető videójátékadatok alkalmasak adatvezérelt elemzések és prediktív modellezési feladatok megvalósítására. Az alkalmazott módszerek nemcsak a prediktív teljesítmény szempontjából bizonyultak hasznosnak, hanem lehetőséget adtak a videójátékok tulajdonságai és a felhasználói visszajelzések közötti összefüggések jobb megértésére is.

9. fejezet

Summary

The aim of this thesis was to analyze video game data obtained from the Steam [1] platform and to formulate different classification problems using machine learning methods. During the research a real, heterogeneous dataset was processed, which contains numerical variables, categorical metadata and textual descriptions. One of the main objectives of the work was to demonstrate how these different types of information can be used in predictive modelling tasks.

The first step of the processing was the cleaning and standardization of the data. This included the handling of missing values, the unification of variable types, and the construction of features suitable for the models. Transforming categorical fields into binary representations, as well as the TF-IDF based vectorization of textual descriptions, made it possible for the different types of data to appear in a common feature space.

The thesis examined two different classification problems. The first task was the estimation of the success of video games based on a label derived from user reviews. In this case structured metadata and numerical variables formed the input of the predictive models. The analysis showed that certain functional characteristics and platform services of games may be related to the success reflected by user feedback.

The second examined task was the automatic separation of multiplayer and singleplayer games. In this case textual descriptions and structured tags proved to be the most informative features. The textual representation made it possible for the models to distinguish between the two categories based on expressions referring to game mechanics and functions.

The comparison of the different classification models showed that both linear and nonlinear methods are capable of producing interpretable and stable predictions. The advantage of linear models primarily appeared in interpretability and in the efficient handling of high-dimensional feature spaces, while ensemble methods in some cases

showed better predictive performance. Overall, the results indicate that the metadata and textual information related to video games are suitable for being used as inputs of machine learning models.

One important conclusion of the thesis is that the combination of structured and textual features can significantly increase the information content of classification models. Game descriptions and metadata do not only contain marketing information, but also implicit signals related to game mechanics and user experience, which may also be useful for predictive models.

The presented approach can be further developed in several directions. One possible direction of future research is the application of more advanced natural language processing methods, for example the use of word embeddings or neural language models. These may be capable of capturing the deeper semantic structure of texts, which could further improve classification performance.

Another possible development direction is the application of more complex machine learning models, for example deep neural networks or more advanced ensemble methods. In addition, the concept of success could be modelled in a more detailed way, for example by using multiclass or regression approaches, where the target variable is not binary but continuous or consists of several categories.

Overall, the thesis demonstrated that the video game data available on the Steam platform are suitable for data-driven analysis and predictive modelling tasks. The applied methods proved to be useful not only from the perspective of predictive performance, but also made it possible to better understand the relationships between the characteristics of video games and user feedback.

Irodalomjegyzék

- [1] Steam platform hivatalos oldala,
<https://store.steampowered.com/>
- [2] Kaggle hivatalos oldala,
<https://www.kaggle.com/>
- [3] Valve hivatalos oldala,
<https://www.valvesoftware.com/hu/>
- [4] Dayi Lin, Cor-Paul Bezemer, Ahmed E. Hassan: An Empirical Study of Game Reviews on the Steam Platform. *Empirical Software Engineering*, 24(1), 170–207, 2019. doi: 10.1007/s10664-018-9627-4
- [5] Andraž De Luisa, Jan Hartman, David Nabergoj, Samo Pahor, Marko Rus, Božidar Stevanoski, Jure Demšar, Erik Štrumbelj: Predicting the Popularity of Games on Steam. In: *Proceedings of the ECML PKDD 2021 Workshop on Data Science for Social Good*, 2021.
- [6] Mohd Nor Akmal Khalid Rizani et al.: A Preliminary Network Analysis on Steam Game Tags: Another Way of Understanding Game Genres. In: *Proceedings of the 2020 DiGRA International Conference*, 2020.
- [7] Python programozási nyelv hivatalos oldala, Python Software Foundation,
<https://www.python.org/>
- [8] Visual Studio Code hivatalos oldala, Microsoft,
<https://code.visualstudio.com/>
- [9] pandas hivatalos oldala, NumFOCUS INC.,
<https://pandas.pydata.org/>
- [10] NumPy hivatalos oldala, NumPy team,
<https://numpy.org/>

-
- [11] matplotlib hivatalos oldala, The matplotlib development team,
<https://matplotlib.org/>
- [12] seaborn hivatalos oldala, Michael Waskom,
<https://seaborn.pydata.org/>
- [13] Scikit-learn: Machine Learning in Python, Pedregosa et al., JMLR 12, pp. 2825-2830, 2011., <https://scikit-learn.org/stable/>
- [14] Jupyter projekt hivatalos oldala
<https://jupyter.org/>
- [15] SteamSpy hivatalos oldala, Sergely Galyonkin,
<https://steamspy.com/>
- [16] A adathalmaz
<https://www.kaggle.com/datasets/nikdavis/steam-store-games>
- [17] B adathalmaz
<https://www.kaggle.com/datasets/fronkongames/steam-games-dataset>
- [18] C adathalmaz
<https://www.kaggle.com/datasets/artermiloff/steam-games-dataset>
- [19] Metacritic hivatalos oldala, FANDOM INC.,
<https://www.metacritic.com/>
- [20] PlantUML hivatalos oldala, Arnaud Roques,
<https://plantuml.com/>
- [21] Steam Direct hivatalos oldala
<https://partner.steamgames.com/steamdirect>
- [22] S. Turney: Pearson Correlation Coefficient (r) | Guide & Examples, Scribbr,
<https://www.scribbr.com/statistics/pearson-correlation-coefficient/>
- [23] Spearman-korreláció
Lukács O. (1987): Matematikai statisztika, Műszaki Könyvkiadó, Budapest.
- [24] Abszolút százalékos hibák, IBM, Cognos Analytics kézikönyv,
<https://www.ibm.com/docs/hu/cognos-analytics/12.1.x?topic=forecasting-statistical-details>

-
- [25] Expanding-window módszer, pandas documentation: Windowing operations
https://pandas.pydata.org/docs/user_guide/window.html
- [26] Szöveges mezők vektorizálása, Manning, C. D., Raghavan, P. és Schütze, H.: Introduction to Information Retrieval
<https://nlp.stanford.edu/IR-book/information-retrieval-book.html>
- [27] Kunné Dr. Tamás Judit: Osztályozási metrikák bináris esetekre,
<https://docs.google.com/presentation/d/1kzSwoxda5UdxYKbzyiup1k8e9F0D8YeV/edit?slide=id.p6#slide=id.p6>
- [28] ROC-AUC, Fawcett, T.: An introduction to ROC analysis
<https://www.sciencedirect.com/science/article/pii/S016786550500303X>
- [29] Interkvartilis terjedelem
<https://www.statisticshowto.com/probability-and-statistics/interquartile-range/>
- [30] Logisztikus regressziós modell
László Kovács: Data Analysis and Data Mining, lecture notes, ME, 2024.
- [31] Random Forest modell
László Kovács: Data Analysis and Data Mining, lecture notes, ME, 2024.
- [32] Gradient Boosting modell
László Kovács: Data Analysis and Data Mining, lecture notes, ME, 2024.
- [33] Lineáris SVM
László Kovács: Data Analysis and Data Mining, lecture notes, ME, 2024.
- [34] spaCy hivatalos weboldala, Explosion,
<https://spacy.io/>
- [35] Daniel Jurafsky and James H. Martin. *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models*. 3rd edition, online manuscript, January 6, 2026. Elérhető: <https://web.stanford.edu/~jurafsky/slp3/>

Az internetes források utolsó ellenőrzése: 2026. május 1.

A CD-melléklet tartalma

A dolgozathoz mellékelte lemezen a `diplomamunka` nevű könyvtárban az alábbi fájlok találhatóak:


- a dolgozat $\text{\LaTeX}$ forráskódja,
- a dolgozat PDF formátumban (`dolgozat.pdf`).
- A dolgozat kiírása Word formátumban a `docs` jegyzékben (`Drig_Dávid_diplomamunka_kiiras.docx`).
- A magyar és angol nyelvű összefoglaló $\text{\LaTeX}$ és PDF formátumban (`8_osszegzes.tex`, `8_osszegzes.pdf`, `9_summary.tex`, `9_summary.pdf`).

A `doc` nevű könyvtár tartalmazza a dolgozathoz kapcsolódó dokumentációkat, valamint a Sphinx alapú `github.io` oldalt.


A `notebooks` könyvtárban a dolgozat elkészítése során létrehozott, illetve a dolgozatban ismertetett Jupyter-munkafüzetek, a hozzájuk tartozó Python-szkriptek, továbbá a munkafüzetek HTML formátumú megjelenítéséhez szükséges szkript és maguk a HTML formátumú munkafüzetek találhatóak.

A. függelék

Relációs adatmodell ábrák




A.1. ábra. Az A adathalmaz normalizálatlan relációs sémája



A.2. ábra. Az A adathalmaz normalizált relációs sémája

game (games.csv)	
♦ <u>appid</u>	int
• name	text
• release_date	date
◦ estimated_owners	int
◦ peak_ccu	int
◦ required_age	int
◦ price	float
◦ DLC_count	int
◦ about_the_game	text
◦ supported_languages	text
◦ full_audio_languages	text
◦ reviews	text
◦ header_image	text
◦ website	text
◦ support_url	text
◦ support_email	text
◦ windows	text
◦ mac	bool
◦ linux	bool
◦ metacritic_score	int
◦ metacritic_url	text
◦ user_score	int
◦ positive	int
◦ negative	int
◦ score_rank	int
◦ achievements	int
◦ recommendations	int
◦ notes	int
◦ average_playtime_forever	int
◦ average_playtime_two_weeks	int
◦ median_playtime_forever	int
◦ median_playtime_two_weeks	int
• developers	text
◦ publishers	text
◦ categories	text
• genres	text
◦ tags	text
◦ screenshots	text
◦ movies	text
◦ discount	int


A.3. ábra. A B adathalmaz normalizálatlan relációs sémája



A.4. ábra. A B adathalmaz normalizált relációs sémája

games_march2025_cleaned		games_march2025_full		games_may2024_cleaned		games_may2024_full	
*appid	int	*appid	int	*appid	int	*appid	int
*name	text	*name	text	*name	text	*name	text
*release_date	date	*release_date	date	*release_date	date	*release_date	date
*required_age	int	*required_age	int	*required_age	int	*required_age	int
*price	float	*price	float	*price	float	*price	float
*dlc_count	int	*dlc_count	int	*dlc_count	int	*dlc_count	int
*detailed_description	text	*detailed_description	text	*detailed_description	text	*detailed_description	text
*about_the_game	text	*about_the_game	text	*about_the_game	text	*about_the_game	text
*short_description	text	*short_description	text	*short_description	text	*short_description	text
*reviews	text	*reviews	text	*reviews	text	*reviews	text
*header_image	text	*header_image	text	*header_image	text	*header_image	text
*website	text	*website	text	*website	text	*website	text
*support_url	text	*support_url	text	*support_url	text	*support_url	text
*support_email	text	*support_email	text	*support_email	text	*support_email	text
*windows	bool	*windows	bool	*windows	bool	*windows	bool
*mac	bool	*mac	bool	*mac	bool	*mac	bool
*linux	bool	*linux	bool	*linux	bool	*linux	bool
*metacritic_score	int	*metacritic_score	int	*metacritic_score	int	*metacritic_score	int
*metacritic_url	text	*metacritic_url	text	*metacritic_url	text	*metacritic_url	text
*achievements	int	*achievements	int	*achievements	int	*achievements	int
*recommendations	text	*recommendations	text	*recommendations	text	*recommendations	text
*notes	text	*notes	text	*notes	text	*notes	text
*supported_languages	text	*supported_languages	text	*supported_languages	text	*supported_languages	text
*full_audio_languages	text	*full_audio_languages	text	*full_audio_languages	text	*full_audio_languages	text
*packages	text	*packages	text	*packages	text	*packages	text
*developers	text	*developers	text	*developers	text	*developers	text
*publishers	text	*publishers	text	*publishers	text	*publishers	text
*categories	text	*categories	text	*categories	text	*categories	text
*genres	text	*genres	text	*genres	text	*genres	text
*screenshots	text	*screenshots	text	*screenshots	text	*screenshots	text
*movies	text	*movies	text	*movies	text	*movies	text
*user_score	int	*user_score	int	*user_score	int	*user_score	int
*score_rank	float	*score_rank	float	*score_rank	float	*score_rank	float
*positive	int	*positive	int	*positive	int	*positive	int
*negative	int	*negative	int	*negative	int	*negative	int
*estimated_owners	text	*estimated_owners	text	*estimated_owners	text	*estimated_owners	text
*average_playtime_forever	int	*average_playtime_forever	int	*average_playtime_forever	int	*average_playtime_forever	int
*average_playtime_two_weeks	int	*average_playtime_two_weeks	int	*average_playtime_two_weeks	int	*average_playtime_two_weeks	int
*median_playtime_forever	int	*median_playtime_forever	int	*median_playtime_forever	int	*median_playtime_forever	int
*median_playtime_two_weeks	int	*median_playtime_two_weeks	int	*median_playtime_two_weeks	int	*median_playtime_two_weeks	int
*discount	int	*discount	int	*discount	int	*discount	int
*peak_ccu	int	*peak_ccu	int	*peak_ccu	int	*peak_ccu	int
*tags	text	*tags	text	*tags	text	*tags	text
*pct_pos_total	int	*pct_pos_total	int	*pct_pos_total	int	*pct_pos_total	int
*pct_pos_recent	int	*pct_pos_recent	int	*pct_pos_recent	int	*pct_pos_recent	int
*num_reviews_total	int	*num_reviews_total	int	*num_reviews_total	int	*num_reviews_total	int
*num_reviews_recent	int	*num_reviews_recent	int	*num_reviews_recent	int	*num_reviews_recent	int


A.5. ábra. A C adathalmaz normalizálatlan relációs sémája




A.6. ábra. A C adathalmaz normalizált relációs sémája

B. függelék

Osztálydiagramok




B.1. ábra. A merge implementációs áttekintése



B.2. ábra. A merge vizualizációs áttekintése

Videogame Data Split - implementációs áttekintés



B.3. ábra. A split művelet megvalósításához készített modulok és kapcsolataik